

TUGAS AKHIR - EC234801

OXYRA: CHATBOT BERBASIS LLM SEBAGAI SISTEM INFORMASI CERDAS KUALITAS UDARA

Cedric Anthony Edysa

NRP 5024 22 1015

Dosen Pembimbing

Muhtadin, S.T., M.T.

NIP 19810609 200912 1 003

Dr. Ahmad Zaini, S.T., M.Sc.

NIP 19750419 200212 1 003

Program Studi Strata 1 (S1) Teknik Komputer

Departemen Teknik Komputer

Fakultas Teknologi Elektro dan Informatika Cerdas

Institut Teknologi Sepuluh Nopember

Surabaya

2026

[Halaman ini sengaja dikosongkan]



TUGAS AKHIR - EC234801

OXYRA: CHATBOT BERBASIS LLM SEBAGAI SISTEM INFORMASI CERDAS KUALITAS UDARA

Cedric Anthony Edysa

NRP 5024 22 1015

Dosen Pembimbing

Muhtadin, S.T., M.T.

NIP 19810609 200912 1 003

Dr. Ahmad Zaini, S.T., M.Sc.

NIP 19750419 200212 1 003

Program Studi Strata 1 (S1) Teknik Komputer

Departemen Teknik Komputer

Fakultas Teknologi Elektro dan Informatika Cerdas

Institut Teknologi Sepuluh Nopember

Surabaya

2026

[Halaman ini sengaja dikosongkan]



FINAL PROJECT - EC234801

OXYRA: AN LLM-BASED CHATBOT AS AN INTELLIGENT AIR QUALITY INFORMATION SYSTEM

Cedric Anthony Edysa

NRP 5024 22 1015

Advisor

Muhtadin, S.T., M.T.

NIP 19810609 200912 1 003

Dr. Ahmad Zaini, S.T., M.Sc.

NIP 19750419 200212 1 003

Undergraduate Study Program of Computer Engineering

Department of Computer Engineering

Faculty of Intelligent Electrical And Informatics Technology

Sepuluh Nopember Institute of Technology

Surabaya

2026

[Halaman ini sengaja dikosongkan]

LEMBAR PENGESAHAN

OXYRA: CHATBOT BERBASIS LLM SEBAGAI SISTEM INFORMASI CERDAS KUALITAS UDARA

TUGAS AKHIR

Diajukan untuk memenuhi salah satu syarat
memperoleh gelar Sarjana Teknik pada
Program Studi S-1 Teknik Komputer
Departemen Teknik Komputer
Fakultas Teknologi Elektro dan Informatika Cerdas
Institut Teknologi Sepuluh Nopember

Oleh: **Cedric Anthony Edysa**
NRP. 5024 22 1015

Disetujui oleh Tim Penguji Tugas Akhir:

Muhtadin, S.T., M.T.
NIP: 19810609 200912 1 003

(Pembimbing I)

.....

Dr. Ahmad Zaini, S.T., M.Sc.
NIP: 19750419 200212 1 003

(Pembimbing II)

.....

Prof. Dr. Ir. Mauridhi Hery Purnomo, M.Eng..
NIP: 19580916 198601 1 001

(Penguji I)

.....

Ir. Hany Boedinugroho, M.T..
NIP: 19610706 198701 1 001

(Penguji II)

.....

Eko Pramunanto, S.T., M.T.
NIP: 19661203 199412 1 001

(Penguji III)

.....

Mengetahui,
Kepala Departemen Teknik Komputer FTEIC - ITS

Dr. Arief Kurniawan, S.T., M.T..
NIP. 19740907200212 1 001

SURABAYA
Juli, 2026

[Halaman ini sengaja dikosongkan]

APPROVAL SHEET

OXYRA: AN LLM-BASED CHATBOT AS AN INTELLIGENT AIR QUALITY INFORMATION SYSTEM

FINAL PROJECT

Submitted to fulfill one of the requirements
for obtaining a degree Bachelor of Engineering at
Undergraduate Study Program of Computer Engineering
Department of Computer Engineering
Faculty of Intelligent Electrical And Informatics Technology
Sepuluh Nopember Institute of Technology

By: **Cedric Anthony Edysa**
NRP. 5024 22 1015

Approved by Final Project Examiner Team:

Muhtadin, S.T., M.T.
NIP: 19810609 200912 1 003

(Advisor I)

.....

Dr. Ahmad Zaini, S.T., M.Sc.
NIP: 19750419 200212 1 003

(Co-Advisor II)

.....

Prof. Dr. Ir. Mauridhi Hery Purnomo, M.Eng..
NIP: 19580916 198601 1 001

(Examiner I)

.....

Ir. Hany Boedinugroho, M.T..
NIP: 19610706 198701 1 001

(Examiner II)

.....

Eko Pramunanto, S.T., M.T.
NIP: 19661203 199412 1 001

(Examiner III)

.....

Acknowledged,
Head of Computer Engineering Department FIEI - ITS

Dr. Arief Kurniawan, S.T., M.T..
NIP. 19740907200212 1 001

SURABAYA
July, 2026

[Halaman ini sengaja dikosongkan]

PERNYATAAN ORISINALITAS

Yang bertanda tangan dibawah ini:

Nama Mahasiswa / NRP : Cedric Anthony Edysa / 5024 22 1015
Departemen : Teknik Komputer
Dosen Pembimbing / NIP : Muhtadin, S.T., M.T. / 19810609 200912 1 003

Dengan ini menyatakan bahwa Tugas Akhir dengan judul "OXYRA: CHATBOT BERBASIS LLM SEBAGAI SISTEM INFORMASI CERDAS KUALITAS UDARA" adalah hasil karya sendiri, bersifat orisinal, dan ditulis dengan mengikuti kaidah penulisan ilmiah.

Bilamana di kemudian hari ditemukan ketidaksesuaian dengan pernyataan ini, maka saya bersedia menerima sanksi sesuai dengan ketentuan yang berlaku di Institut Teknologi Sepuluh Nopember.

Surabaya, Juli 2026

Mengetahui
Dosen Pembimbing

Mahasiswa

Muhtadin, S.T., M.T.
NIP. 19810609 200912 1 003

Cedric Anthony Edysa
NRP. 5024 22 1015

[Halaman ini sengaja dikosongkan]

STATEMENT OF ORIGINALITY

The undersigned below:

Name of student / NRP : Cedric Anthony Edysa / 5024 22 1015
Department : Computer Engineering
Advisor / NIP : Muhtadin, S.T., M.T. / 19810609 200912 1 003

Hereby declared that the Final Project with the title of "OXYRA: AN LLM-BASED CHATBOT AS AN INTELLIGENT AIR QUALITY INFORMATION SYSTEM" is the result of my own work, is original, and is written by following the rules of scientific writing.

If in future there is a discrepancy with this statement, then I am willing to accept sanctions in accordance with provisions that apply at Sepuluh Nopember Institute of Technology.

Surabaya, July 2026

Acknowledged
Advisor

Student

Muhtadin, S.T., M.T.
NIP. 19810609 200912 1 003

Cedric Anthony Edysa
NRP. 5024 22 1015

[Halaman ini sengaja dikosongkan]

ABSTRAK

Nama Mahasiswa : Cedric Anthony Edysa
Judul Tugas Akhir : OXYRA: CHATBOT BERBASIS LLM SEBAGAI SISTEM INFORMASI CERDAS KUALITAS UDARA
Pembimbing : 1. Muhtadin, S.T., M.T.
2. Dr. Ahmad Zaini, S.T., M.Sc.

Penelitian ini mengembangkan Oxyra, sebuah *chatbot* berbasis LLM yang menyederhanakan informasi kualitas udara sekaligus menekan halusinasi melalui pemisahan peran: seluruh nilai numerik diambil kode program melalui mekanisme pemanggilan fungsi (*tool calling*), saran tindakan ditetapkan secara deterministik berdasarkan kategori AQI standar US EPA, sedangkan model bahasa hanya merangkai jawaban—sehingga kecerdasan sistem terletak pada pemahaman maksud kalimat pengguna dan pembahasaan hasil, bukan pada peramalan maupun analisis data. Sistem dilengkapi strategi anti-halusinasi berlapis berupa gerbang pertanyaan di luar lingkup, validasi wilayah, dan penguraian pertanyaan majemuk. Arsitektur yang sama diterapkan pada dua subsistem dengan karakteristik data berbeda, yaitu data *real-time* 16 kota di Jawa Timur dan data historis US EPA yang nilai AQI-nya dihitung sendiri dari konsentrasi mentah.

Pengujian dilakukan menggunakan 40 pertanyaan yang dikumpulkan dari responden masyarakat awam. Jawaban sistem dengan model inti Llama 3.1 8B memperoleh skor rata-rata 8,58 dari skala 5–10 pada penilaian ahli terhadap dua belas pertanyaan perwakilan, dibandingkan 8,25 pada model pembanding Qwen3 8B. Audit terhadap 80 jawaban yang dihasilkan tiap model menunjukkan model inti tidak menyampaikan satu pun kondisi tanpa dukungan data, sedangkan model pembanding menyampaikannya pada enam jawaban. Validasi terhadap 18 pertanyaan berkueri acuan pada subsistem US EPA menunjukkan kesesuaian penuh dengan basis data. Seluruh halusinasi model pembanding terjadi ketika model tidak memanggil fungsi, sehingga kepatuhan terhadap mekanisme *tool calling* teridentifikasi sebagai penentu keandalan sistem. Pengujian preferensi tersamar terhadap 10 responden awam menunjukkan mayoritas responden memilih jawaban sistem dibandingkan jawaban model bahasa yang sama tanpa arsitektur yang dikembangkan pada keempat pasangan pertanyaan yang diujikan.

Kata kunci: *Large Language Model, chatbot, tool calling, halusinasi, kualitas udara, Air Quality Index*

[Halaman ini sengaja dikosongkan]

ABSTRACT

Name : Cedric Anthony Edysa
Title : OXYRA: AN LLM-BASED CHATBOT AS AN INTELLIGENT AIR QUALITY INFORMATION SYSTEM
Advisors : 1. Muhtadin, S.T., M.T.
2. Dr. Ahmad Zaini, S.T., M.Sc.

This research develops Oxyra, an LLM-based chatbot that simplifies air quality information while suppressing hallucination through a separation of roles: all numerical values are retrieved by program code through a tool-calling mechanism, action recommendations are determined deterministically based on the US EPA AQI categories, and the language model is limited to composing the answer—so that the system’s intelligence lies in understanding the user’s intent and verbalizing the results, rather than in forecasting or data analysis. The system is equipped with a layered anti-hallucination strategy consisting of an out-of-scope question gate, region validation, and compound-question decomposition. The same architecture is applied to two subsystems with different data characteristics, namely real-time data from 16 cities in East Java and historical US EPA data whose AQI values are computed independently from raw concentrations.

Testing was conducted using 40 questions collected from lay respondents. Answers produced by the core model, Llama 3.1 8B, obtained an average score of 8.58 on a 5–10 scale in an expert assessment of twelve representative questions, compared to 8.25 for the comparison model, Qwen3 8B. An audit of 80 answers per model showed that the core model conveyed no actual condition unsupported by data, whereas the comparison model did so in six answers. . Validation of 18 questions with reference queries on the US EPA subsystem showed full agreement with the database. All hallucinations of the comparison model occurred when the model did not invoke a function, identifying compliance with the tool-calling mechanism as a determinant of system reliability. A blinded preference test with 10 lay respondents showed that the majority of respondents favored the system’s answers over those of the same base model without the developed architecture across all four question pairs tested.

Keywords: Large Language Model, chatbot, tool calling, hallucination, air quality, Air Quality Index

[Halaman ini sengaja dikosongkan]

KATA PENGANTAR

Puji dan syukur kehadiran Tuhan Yang Maha Esa, atas segala rahmat dan karunia-Nya, sehingga penulis dapat menyelesaikan penelitian ini yang berjudul OXYRA: CHATBOT BERBASIS LLM SEBAGAI SISTEM INFORMASI CERDAS KUALITAS UDARA

Penelitian ini disusun dalam rangka pemenuhan Tugas Akhir sebagai syarat kelulusan Mahasiswa ITS. Oleh karena itu, penulis mengucapkan terima kasih kepada:

1. Bapak Dr. Arief Kurniawan, S.T., M.T., selaku Kepala Departemen Teknik Komputer, Fakultas Teknologi Elektro dan Informatika Cerdas, Institut Teknologi Sepuluh Nopember.
2. Bapak Muhtadin, S.T., M.T. selaku Dosen Pembimbing I dan Bapak Dr. Ahmad Zaini, S.T., M.Sc. selaku Dosen Pembimbing II yang telah memberikan arahan dan membantu penulis selama pengerjaan tugas akhir ini.
3. Bapak Prof. Ir. Joni Hermawan, M.Sc.ES., Ph.D., yang telah berkenan meluangkan waktu sebagai validator ahli dalam menilai kualitas jawaban sistem yang dikembangkan pada penelitian ini.
4. Bapak-Ibu dosen pengajar Departemen Teknik Komputer, atas ilmu yang telah diberikan kepada penulis selama menjalani masa perkuliahan.
5. Seluruh responden yang telah bersedia berpartisipasi mengisi kuesioner penelitian ini. Pertanyaan-pertanyaan yang disampaikan responden menjadi dasar penyusunan instrumen pengujian dan sangat menentukan arah pengembangan sistem.
6. Kedua Orangtua, Adik, Kakek, Nenek, dan keluarga yang telah memberikan doa serta dukungan selama penulis mengenyam pendidikan.
7. Teman-teman Laboratorium *Robotics and Intelligent System* yang membantu penulis dalam pengerjaan tugas akhir ini.
8. Teman-teman Teknik Komputer yang memberikan motivasi dan semangat selama masa perkuliahan.

Akhir kata, penulis menyadari bahwa buku ini masih jauh dari sempurna. Meskipun demikian, penulis berharap penelitian ini dapat memberikan manfaat kepada banyak pihak serta menjadi rujukan bagi pengembangan penelitian sejenis di masa mendatang.

Surabaya, Juli 2026

Cedric Anthony Edysa

[Halaman ini sengaja dikosongkan]

DAFTAR ISI

ABSTRAK	i
ABSTRACT	iii
KATA PENGANTAR	v
DAFTAR ISI	vii
DAFTAR GAMBAR	xi
DAFTAR TABEL	xiii
1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Tujuan Penelitian	4
1.4 Batasan Masalah	4
1.5 Manfaat	5
2 KAJIAN PUSTAKA	7
2.1 Hasil Penelitian Terdahulu	7
2.2 Dasar Teori	8
2.2.1 <i>Large Language Model</i> (LLM)	8
2.2.2 Halusinasi pada LLM dan <i>Grounding</i>	9
2.2.3 <i>Retrieval Augmented Generation</i> (RAG)	10
2.2.4 Pemanggilan Fungsi (<i>Function Calling</i>)	10
2.2.5 Sistem <i>Question Answering</i> (QA)	11
2.2.6 Kualitas Udara	11
2.2.7 <i>Air Quality Index</i> (AQI)	12
3 METODOLOGI	15
3.1 Gambaran Umum Metodologi Penelitian	15
3.1.1 Blok Diagram Penelitian	15
3.2 Tahapan Penelitian	17

3.2.1	Pengumpulan Data	17
3.2.2	Ekstraksi Data dari Respons API	18
3.2.3	Pemrosesan Awal Data	19
3.2.4	Perhitungan AQI	19
3.2.5	Pengembangan Sistem Chatbot	20
3.2.6	Arsitektur Anti-Halusinasi	22
3.2.7	Analisis Pola Historis	23
3.2.8	<i>Deployment</i> pada VPS	24
3.2.9	Integrasi Frontend dan Backend	24
3.2.10	Pengujian dan Evaluasi	24
3.3	Gambaran Umum Sistem	26
3.4	Alat dan Bahan	28
3.4.1	Perangkat Keras	28
3.4.2	Perangkat Lunak	28
4	PENGUJIAN	31
4.1	Tujuan Pengujian	31
4.2	Hasil Implementasi Sistem	31
4.3	Pengujian Akurasi Subsistem US EPA	34
4.3.1	Prosedur Pengujian	34
4.3.2	Hasil dan Analisis	35
4.4	Pengujian Strategi Anti-Halusinasi	35
4.4.1	Temuan Awal	35
4.4.2	Perbaikan yang Diterapkan	36
4.4.3	Hasil Verifikasi	36
4.5	Perbandingan Model Tanpa dan Dengan Arsitektur Oxyra	38
4.6	Pengujian Kepuasan Responden terhadap Jawaban Sistem	40
4.7	Pengujian Persepsi Awam Subsistem Jawa Timur	42
4.7.1	Prosedur Pengujian	42
4.7.2	Karakteristik Responden	42
4.7.3	Karakteristik Pertanyaan Awam	43
4.7.4	Hasil Penilaian Ahli	45
4.8	Pengujian Komparatif Dua Model LLM	46
4.8.1	Rancangan Pengujian	46
4.8.2	Hasil dan Analisis	47

4.9	Analisis Pola Historis	50
4.10	Analisis dan Keterbatasan	52
4.10.1	Analisis Keseluruhan	52
4.10.2	Keterbatasan	52
5	PENUTUP	55
5.1	Kesimpulan	55
5.2	Saran	56
	DAFTAR PUSTAKA	59
	LAMPIRAN	61
	Lampiran A. Isi Kuesioner Responden	61
	Lampiran B. Lembar Penilaian Ahli	62
	Lampiran C. Waktu Respons Pengujian	63
	BIOGRAFI PENULIS	65

[Halaman ini sengaja dikosongkan]

DAFTAR GAMBAR

2.1	Skema alur kerja umum <i>Large Language Model</i>	9
3.1	Blok Diagram Penelitian	16
3.2	Alur Mekanisme <i>Tool Calling</i>	21
3.3	Alur Penyaringan Anti-Halusinasi	23
3.4	Tampilan Kuesioner Daring Pengumpulan Pertanyaan	26
3.5	Alur Pengujian Persepsi Awam	26
3.6	Arsitektur Sistem Oxyra	27
4.1	Tampilan halaman <i>dashboard</i> sistem Oxyra	32
4.2	Contoh Respons Sistem terhadap Pertanyaan Edukatif	32
4.3	Contoh Respons Sistem terhadap Pertanyaan Kondisi Udara Terkini	32
4.4	Visualisasi Perbandingan AQI Antarkota	33
4.5	Visualisasi Tren AQI Satu Kota pada Rentang Waktu Terpilih	34
4.6	Penolakan Pertanyaan di Luar Lingkup (Kadar Oksigen)	36
4.7	Permintaan Klarifikasi pada Lokasi Tidak Spesifik	37
4.8	Penanganan Pertanyaan Majemuk	37
4.9	Cuplikan Jawaban Model Mentah (Llama 3.1 melalui Ollama) tanpa Arsitektur Oxyra	39
4.10	Jawaban Sistem Oxyra terhadap Pertanyaan yang Sama	39
4.11	Contoh Pasangan Jawaban Tersamar pada Kuesioner Kepuasan	41
4.12	Distribusi Usia Responden Kuesioner	43
4.13	Respons Subsistem US EPA atas Pertanyaan Bertanggal Spesifik	49
4.14	Hasil Kueri Acuan pada Basis Data untuk Pertanyaan yang Sama	49
4.15	Contoh Respons Model Pembanding Qwen3 pada Pertanyaan yang Sama	50
4.16	Contoh Visualisasi Tren AQI pada Jawaban Sistem	51
4.17	Contoh Jawaban Pertanyaan Berorientasi Aktivitas Berbasis Pola Historis	51
4.18	Contoh Jawaban Pola Waktu Harian dengan Pembingkai Non-Prediktif	51

[Halaman ini sengaja dikosongkan]

DAFTAR TABEL

2.1	Komponen Polutan Udara Utama	12
2.2	Kategori Air Quality Index (AQI) Skala US EPA	13
3.1	Nilai Hasil Ekstraksi pada Kedua Subsystem	18
3.2	Kategori Kualitas Udara Berdasarkan Nilai AQI (US EPA)	20
3.3	Contoh <i>Breakpoint</i> Konsentrasi dan Indeks AQI (US EPA)	20
4.1	Hasil Validasi Akurasi terhadap Kueri Acuan Basis Data US EPA	35
4.2	Perbandingan Jawaban Model Mentah dan Sistem Oxyra (Model Dasar Sama) .	40
4.3	Hasil Pengujian Kepuasan Responden (10 Responden)	42
4.4	Pertanyaan Responden yang Diujikan dan Dinilai Ahli	44
4.5	Skor Penilaian Ahli per Pertanyaan (Skala 5–10)	46
4.6	Rekapitulasi Pengujian Komparatif Llama 3.1 8B dan Qwen3 8B	48

[Halaman ini sengaja dikosongkan]

BAB I

PENDAHULUAN

1.1 Latar Belakang

Polusi udara telah menjadi salah satu tantangan lingkungan dan kesehatan masyarakat paling signifikan di tingkat global maupun nasional. *World Health Organization* (WHO) melaporkan bahwa polusi udara bertanggung jawab atas jutaan kematian prematur setiap tahunnya, dengan partikulat halus ($PM_{2.5}$) menjadi salah satu polutan paling berbahaya bagi kesehatan manusia. Di Indonesia, fenomena ini semakin mengkhawatirkan seiring dengan meningkatnya urbanisasi dan industrialisasi, khususnya di kota-kota metropolitan seperti Surabaya. Data kualitas udara seringkali menunjukkan bahwa konsentrasi polutan secara berkala melampaui ambang batas aman yang direkomendasikan, membawa implikasi serius terhadap kesehatan pernapasan dan kardiovaskular penduduk. Tantangan ini diperparah oleh rendahnya literasi lingkungan di kalangan masyarakat umum. Data kualitas udara yang tersedia melalui berbagai platform seringkali disajikan dalam bentuk indeks atau angka mentah yang sulit diinterpretasikan, sehingga gagal mendorong tindakan preventif yang efektif. Tantangan lain yang teramati adalah adanya inkonsistensi antara *Air Quality Index* (AQI) yang dipublikasikan dan persepsi risiko kesehatan di masyarakat, yang menunjukkan adanya kesenjangan komunikasi antara data dan pemahaman publik.

Besarnya dampak polusi udara terhadap kesehatan menjadikannya persoalan yang mendasak untuk ditangani. *World Health Organization* memperkirakan bahwa hampir seluruh populasi dunia menghirup udara yang melampaui batas aman yang direkomendasikan, dan ...paparan jangka panjang terhadap partikulat halus berkaitan dengan berbagai gangguan pernapasan dan kardiovaskular [1]. Di wilayah perkotaan dengan kepadatan aktivitas tinggi, konsentrasi polutan cenderung berfluktuasi sepanjang hari mengikuti pola aktivitas manusia, sehingga informasi mengenai kapan dan di mana kualitas udara memburuk menjadi sama pentingnya dengan informasi mengenai tingkat polusi itu sendiri. Kondisi kualitas udara juga dapat bervariasi secara signifikan dalam satu kota, sebagaimana ditunjukkan oleh pemantauan bergerak di Jakarta yang menemukan perbedaan konsentrasi $PM_{2.5}$ antarwilayah dalam satu kota [2]. Hal ini menegaskan bahwa informasi kualitas udara berbasis satu titik pantau perlu disampaikan sebagai indikasi pada skala kota, bukan sebagai nilai yang berlaku pada lokasi spesifik pengguna. Kondisi ini menegaskan perlunya sistem yang tidak sekadar menampilkan angka, tetapi juga membantu masyarakat memahami dan menindaklanjuti informasi tersebut secara tepat waktu.

Kesenjangan pemahaman ini menjadi semakin krusial bagi kelompok masyarakat yang beraktivitas di luar ruangan dalam durasi panjang dan terpapar polusi udara secara langsung, namun tidak memiliki pemahaman maupun alat yang memadai untuk menafsirkan data kualitas udara. Kelompok tersebut mencakup wisatawan yang tidak terbiasa dengan kondisi lingkungan setempat, olahragawan yang melakukan aktivitas seperti berlari dan bersepeda di area terbuka, serta pekerja yang aktivitasnya berhubungan langsung dengan jalanan seperti pengemudi ojek

daring, kurir, dan pedagang kaki lima. Informasi kualitas udara yang disederhanakan dan disertai rekomendasi tindakan menjadi kebutuhan nyata bagi kelompok-kelompok ini untuk melindungi kesehatan mereka.

Kesenjangan tersebut pada dasarnya bukan kesenjangan ketersediaan data, melainkan kesenjangan antarmuka antara bahasa manusia dan data terstruktur. Sistem informasi kualitas udara yang ada saat ini berupa portal, aplikasi, dan papan informasi publik yang menyajikan indeks dalam format tampilan tetap dan hanya dapat diakses melalui antarmuka menu atau kueri terstruktur. Masyarakat awam tidak merumuskan kebutuhan informasinya dalam bentuk kueri, melainkan dalam kalimat sehari-hari yang beragam strukturnya dan kerap tidak baku; inti pertanyaan yang sama dapat disampaikan melalui struktur kalimat yang berbeda-beda, dan sistem berbasis antarmuka kaku tidak mampu memahami kesamaan maksud tersebut. Akibatnya, data yang sebenarnya telah tersedia tidak dapat dimanfaatkan secara efektif oleh masyarakat awam. Kecerdasan yang dibutuhkan untuk menjembatani kesenjangan ini terletak pada lapisan bahasa: memahami maksud kalimat awam, menerjemahkannya menjadi aksi pengambilan data yang tepat, lalu membahasakan hasilnya kembali dalam bahasa yang mudah dipahami.

Perkembangan sistem percakapan cerdas atau *chatbot* menawarkan paradigma baru dalam diseminasi informasi. Penelitian Caldarini et al. [3] mengulas evolusi *chatbot* yang telah bergerak dari sistem berbasis aturan sederhana menuju agen percakapan yang lebih dinamis dan cerdas. Kemajuan ini didukung oleh kemunculan *Large Language Models* (LLM), yaitu model kecerdasan buatan yang dilatih pada data teks masif dan mampu memahami serta menghasilkan teks layaknya manusia. Penelitian oleh Kooli [4] menyoroti potensi besar *chatbot* dalam konteks edukasi dan riset, dimana teknologi ini dapat berfungsi sebagai medium penyampaian informasi yang interaktif dan personal. Kapabilitas LLM memungkinkan *chatbot* tidak hanya menyajikan data, namun juga menerjemahkannya menjadi wawasan yang dapat ditindaklanjuti (*actionable insights*) oleh masyarakat, seperti memberikan rekomendasi tindakan preventif yang disesuaikan dengan kondisi kualitas udara secara *real-time* dan informasi mengenai konsekuensi dari kualitas udara yang buruk.

Meskipun model bahasa menawarkan kemampuan komunikasi yang luwes, penerapannya pada penyampaian informasi kualitas udara memunculkan tantangan tersendiri, yaitu risiko halusinasi. Model bahasa pada dasarnya menghasilkan teks berdasarkan pola statistik, sehingga berpotensi menghasilkan informasi yang tampak meyakinkan namun tidak didukung oleh data sebenarnya. Dalam konteks informasi kesehatan, hal ini sangat berbahaya, karena informasi yang keliru dapat menyesatkan masyarakat dalam mengambil tindakan. Kebutuhan ini menuntut sistem yang tidak hanya interaktif dan mudah dipahami, tetapi juga mampu menjamin bahwa informasi faktual yang disampaikan benar-benar bersumber dari data yang sah. Kebutuhan akan keakuratan inilah yang menjadi salah satu fokus utama pengembangan pada penelitian ini.

Penelitian ini juga menguji ketahanan pendekatan yang dikembangkan pada dua konteks data yang berbeda karakteristiknya, agar pendekatan tersebut tidak terbatas pada satu jenis data saja. Konteks pertama adalah data kualitas udara *real-time* untuk wilayah Jawa Timur, yang merepresentasikan tantangan penyediaan informasi terkini kepada masyarakat. Konteks kedua adalah data historis berbasis standar *United States Environmental Protection Agency* (US EPA), yang memiliki kelengkapan konsentrasi mentah tiap polutan dan memungkinkan pengujian akurasi perhitungan secara lebih rinci. Penerapan arsitektur yang sama pada kedua konteks tersebut memungkinkan penelitian ini menilai sejauh mana pendekatan yang dikembangkan bersifat umum dan tidak bergantung pada satu sumber data tertentu.

Penerapan LLM untuk tugas-tugas yang melibatkan data terstruktur, seperti data tabel dari API lingkungan, telah menunjukkan potensi yang signifikan. Yang et al. [5] mendemonstrasikan bahwa LLM yang disesuaikan untuk tugas-tugas prediktif pada data tabular mampu mencapai peningkatan performa yang luar biasa, menggarisbawahi kelayakan penggunaan LLM untuk menganalisis data sensorik. Studi kasus relevan oleh Patel et al. [6] melalui proyek “VayuBuddy” di India berhasil mengembangkan *chatbot* berbasis LLM untuk mendemokratisasi akses terhadap data kualitas udara dari *Pollution Control Board* (CPCB). VayuBuddy menunjukkan bahwa LLM dapat secara efektif mengubah *query* bahasa alami dari pengguna menjadi analisis data yang relevan dan menyajikannya kembali dalam format yang mudah dipahami. Keberhasilan dan potensi tersebut mendorong penelitian ini untuk mengadaptasi dan mengembangkan pendekatan serupa dengan penekanan pada keakuratan informasi dan pencegahan halusinasi, dengan harapan dapat menjembatani kesenjangan informasi dan meningkatkan kesadaran serta kapasitas masyarakat untuk melakukan tindakan preventif terhadap dampak buruk polusi udara.

Kecerdasan sistem terletak pada lapisan pemahaman dan perangkaian bahasa, bukan pada peramalan. Sistem dirancang secara non-prediktif pada analisis data, yang dilakukan secara deterministik oleh kode program. Mesin bahasa yang digunakan merupakan model yang telah tersedia secara terbuka; kontribusi penelitian ini terletak pada arsitektur yang mengarahkan, membatasi, dan mengoreksi keluaran mesin tersebut agar interpretasi maksud pengguna menghasilkan pengambilan data yang benar dan jawaban yang dapat dipertanggungjawabkan.

1.2 Rumusan Masalah

Meskipun data kualitas udara telah tersedia melalui berbagai portal web dan aplikasi, penyajiannya yang bersifat pasif dan teknis menjadi penghalang utama bagi masyarakat umum untuk memahami makna informasi tersebut. Sistem informasi yang ada saat ini cenderung hanya menampilkan angka indeks (AQI) tanpa memberikan konteks, interpretasi risiko, atau rekomendasi tindakan preventif yang personal dan mudah dipahami. Hal ini menimbulkan beberapa masalah fundamental:

1. Sistem informasi kualitas udara yang ada saat ini memiliki keterbatasan dalam memahami kalimat bahasa alami masyarakat awam. Pengguna dapat menyampaikan inti pertanyaan yang sama melalui struktur kalimat yang berbeda-beda, termasuk dengan bahasa yang tidak baku, sedangkan sistem yang ada hanya dapat diakses melalui antarmuka atau kueri yang kaku, sehingga maksud pengguna tidak dapat dipahami dan data yang sebenarnya tersedia tidak dapat dimanfaatkan. *Large Language Model* (LLM) menawarkan kemampuan memahami variasi kalimat tersebut; namun keluaran model tidak serta-merta menjadi kueri pengambilan data yang benar, sehingga diperlukan mekanisme penyesuaian yang menerjemahkan maksud pengguna menjadi kueri yang tepat serta membahasakan hasil kueri kembali menjadi jawaban yang dipahami masyarakat awam.
2. Keterbatasan sistem informasi kualitas udara yang ada dalam memberikan rekomendasi tindakan preventif yang bersifat personal dan mudah dipahami oleh masyarakat awam, meskipun data kualitas udara *real-time* telah tersedia secara publik.
3. Penggunaan *Large Language Model* sebagai media penyampaian informasi pada dua masalah di atas menghadirkan risiko yang dikenal sebagai halusinasi atau membuat interpretasi sendiri terhadap pertanyaan yang diberikan oleh user. Pada informasi yang

menyangkut kesehatan masyarakat, jawaban semacam itu dapat menyesatkan pengambilan keputusan pengguna, sehingga dibutuhkan mekanisme pengendalian yang menjamin seluruh informasi faktual bersumber dari data yang dimiliki sistem.

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah diuraikan, tujuan dari penelitian ini adalah:

1. Mengembangkan sistem *chatbot* yang mampu memahami pertanyaan bahasa alami masyarakat awam dengan beragam struktur kalimat dan ejaan tidak baku, menerjemahkannya menjadi pemanggilan fungsi dan kueri pengambilan data yang tepat, serta membahasakan hasilnya kembali menjadi jawaban yang interaktif dan mudah dipahami.
2. Menyediakan rekomendasi tindakan preventif yang relevan dan mudah dipahami berdasarkan kondisi kualitas udara *real-time* serta konteks aktivitas pengguna, guna membantu pengguna dalam mengambil keputusan sehari-hari terkait aktivitas luar ruang dan perlindungan diri.
3. Menerapkan mekanisme pengendalian halusinasi pada *chatbot* berbasis LLM agar seluruh informasi faktual yang disampaikan selalu berlandaskan data kualitas udara yang dimiliki sistem.

1.4 Batasan Masalah

Batasan masalah pada penelitian ini ditetapkan sebagai berikut agar penelitian tetap terarah dan fokus:

1. Wilayah Cakupan dan Keterbatasan Data

Informasi kualitas udara *real-time* dibatasi pada 16 kota di Provinsi Jawa Timur. Pembatasan ini disesuaikan dengan keterbatasan data yang disediakan secara publik oleh sumber data yang digunakan, yaitu: (a) cakupan lokasi di Jawa Timur yang tersedia melalui IQAir API terbatas pada 16 kota tersebut; (b) IQAir API pada paket gratis (*community*) membatasi jumlah panggilan sebanyak 10.000 panggilan per bulan, sehingga pengambilan data dilakukan dengan interval dua jam agar tetap berada dalam kuota; dan (c) data tiap kota berasal dari satu titik pemantauan, sehingga nilai yang disajikan merupakan indikasi pada skala kota. Sebagai konteks pembanding, digunakan data historis wilayah Amerika Serikat yang mencakup 53 negara bagian dan 740 *county*.

2. Sumber Data

Data kualitas udara *real-time* Jawa Timur diperoleh dari IQAir API, berupa nilai AQI standar US EPA, polutan dominan, dan parameter kelembapan. Data historis Amerika Serikat diperoleh dari basis data pemantauan *United States Environmental Protection Agency* (US EPA) untuk empat polutan gas, yaitu ozon (O₃), nitrogen dioksida (NO₂), sulfur dioksida (SO₂), dan karbon monoksida (CO).

3. Model LLM

Model bahasa dijalankan secara lokal melalui Ollama. Model inti yang digunakan adalah Llama 3.1 8B, dengan Qwen3 8B sebagai model pembanding pada pengujian komparatif.

Pemilihan model dibatasi pada model yang mendukung mekanisme pemanggilan fungsi (*tool calling*), karena mekanisme tersebut menjadi landasan arsitektur sistem.

4. Fokus Fungsionalitas

Sistem dirancang untuk empat fungsi utama: (a) menyampaikan kondisi kualitas udara terkini beserta interpretasinya, (b) memberikan saran tindakan preventif berdasarkan kategori AQI standar US EPA, (c) menyajikan analisis pola historis jangka pendek yang dibingkai sebagai gambaran pola dan bukan prediksi, serta (d) memberikan edukasi umum mengenai polutan dan kualitas udara. Penjelasan kaitan kualitas udara dengan kesehatan dibatasi pada penjelasan kualitatif umum; sistem tidak memberikan diagnosis, tidak menyebutkan penyakit spesifik, dan tidak memberikan saran medis.

5. Evaluasi

Evaluasi sistem dibatasi pada validasi akurasi jawaban terhadap basis data pada subsistem US EPA, pengujian menggunakan pertanyaan yang dikumpulkan dari responden masyarakat awam pada subsistem Jawa Timur, penilaian kualitas jawaban sistem oleh ahli, serta pengujian komparatif antarmodel LLM pada *pipeline* yang sama.

6. Bahasa

Interaksi utama antara pengguna dan *chatbot* dilakukan dalam Bahasa Indonesia.

1.5 Manfaat

Hasil dari penelitian ini diharapkan dapat memberikan manfaat dari berbagai aspek, antara lain:

1. **Manfaat Akademik:** Penelitian ini akan memperkaya literatur ilmiah mengenai penerapan *Large Language Models* (LLM) dalam domain teknik lingkungan dan kesehatan masyarakat, khususnya sebagai studi kasus integrasi LLM dengan data sensorik *real-time* untuk diseminasi informasi di negara berkembang.
2. **Manfaat Sosial dan Edukasi:** Meningkatkan literasi dan kesadaran publik mengenai risiko polusi udara, khususnya di wilayah Jawa Timur. Akses informasi yang mudah dan interaktif memungkinkan masyarakat lebih proaktif dalam menjaga kesehatan mereka dan memahami kondisi lingkungan sekitarnya.
3. **Manfaat Praktis:** Menghasilkan sebuah prototipe fungsional yang dapat menjadi alat bantu pengambilan keputusan sehari-hari bagi masyarakat, seperti menentukan waktu yang aman untuk beraktivitas di luar ruangan, memilih lokasi dengan kualitas udara yang lebih baik, atau menggunakan alat pelindung diri yang sesuai.
4. **Manfaat Teknologi:** Memberikan wawasan mengenai arsitektur sistem untuk integrasi LLM dengan sumber data API eksternal secara dinamis, serta menyajikan metodologi evaluasi performa LLM yang melibatkan penilaian kuantitatif dan kualitatif berbasis responden manusia untuk aplikasi domain spesifik.

[Halaman ini sengaja dikosongkan]

BAB II

KAJIAN PUSTAKA

Pada bab ini akan dibahas tinjauan penelitian terdahulu dan teori penunjang terkait dengan penelitian yang dilakukan. Dengan demikian penelitian ini menjadi lebih terarah.

2.1 Hasil Penelitian Terdahulu

Evolusi sistem percakapan cerdas atau *chatbot* telah mengalami transformasi fundamental dalam satu dekade terakhir. Penelitian oleh Caldarini et al. [3] dalam survei literaturnya memetakan perkembangan *chatbot* dari sistem berbasis aturan (*rule-based*) yang kaku dan domain-spesifik, menuju arsitektur berbasis *Artificial Intelligence* (AI) yang lebih fleksibel. Perkembangan ini mencapai puncaknya dengan adopsi *Large Language Models* (LLM), yang memungkinkan *chatbot* untuk memahami konteks, menghasilkan respons yang natural, dan berinteraksi secara lebih dinamis. Transisi ini membuka peluang aplikasi *chatbot* di berbagai sektor yang sebelumnya sulit dijangkau, termasuk sebagai medium diseminasi informasi kompleks seperti data lingkungan.

Pemanfaatan *chatbot* dalam bidang edukasi dan riset menjadi semakin relevan sejalan dengan kemajuan teknologi tersebut. Kooli [4] menganalisis peran *chatbot* sebagai alat bantu edukasi yang personal dan interaktif, yang mampu meningkatkan keterlibatan pengguna dan pemahaman terhadap topik yang kompleks. Kooli turut menyoroti implikasi etis yang perlu ditimbang, seperti potensi bias dalam data pelatihan, akurasi informasi, dan privasi pengguna. Tantangan etis ini menjadi krusial dalam konteks sistem informasi kualitas udara, karena penyampaian informasi yang tidak akurat dapat berdampak langsung pada keputusan kesehatan masyarakat. Kondisi tersebut menuntut pengembangan *chatbot* di domain ini untuk memiliki mekanisme yang memastikan keandalan dan validitas informasi yang disampaikan.

Tantangan teknis utama dalam aplikasi LLM untuk analisis lingkungan adalah kemampuannya memproses data terstruktur yang berasal dari sensor atau API. Penelitian oleh Yang et al. [5] secara spesifik menunjukkan bahwa LLM, melalui *pre-training* yang disesuaikan, mampu membaca dan melakukan tugas prediktif pada data terstruktur dengan performa yang signifikan. Kemampuan ini membuktikan bahwa LLM tidak hanya terbatas pada pemrosesan teks bebas, tetapi juga dapat dilatih untuk memahami relasi dan pola dalam data numerik dan kategorikal, seperti data konsentrasi polutan, waktu, dan lokasi. Temuan ini menjadi landasan teknis yang kuat untuk pengembangan *chatbot* kualitas udara yang tidak hanya menampilkan data, tetapi juga menganalisisnya untuk menghasilkan wawasan.

Studi kasus paling relevan yang mengintegrasikan seluruh konsep di atas adalah VayuBuddy, yang dikembangkan oleh Patel et al. [6]. VayuBuddy adalah *chatbot* berbasis LLM yang dirancang untuk mendemokratisasi akses data kualitas udara di India. Sistem ini bekerja dengan menerjemahkan pertanyaan pengguna dalam bahasa alami menjadi skrip Python untuk analisis data, kemudian menyajikan hasilnya dalam format visual atau tekstual yang mudah dipahami.

Keberhasilan VayuBuddy menunjukkan kelayakan model konseptual dan teknis dari *chatbot* sebagai jembatan antara data sensorik mentah dan pemahaman publik. Penelitian tersebut turut menyoroti pentingnya konteks lokal, karena VayuBuddy dioptimalkan untuk sumber data dan kebutuhan pemangku kepentingan di India.

Pemanfaatan data terbuka kualitas udara untuk penyajian informasi juga telah dikembangkan pada konteks perkotaan Eropa oleh Miasayedava et al. [7], yang menunjukkan bahwa data pemantauan terbuka dapat diolah menjadi informasi yang dapat diakses publik secara ringan. Penelitian tersebut menegaskan bahwa ketersediaan data terbuka merupakan prasyarat, namun belum menjamin informasi tersebut dapat dipahami dan ditindaklanjuti oleh masyarakat awam.

Tinjauan penelitian terdahulu tersebut menunjukkan adanya sebuah kesenjangan penelitian (*research gap*) yang signifikan. Meskipun kerangka teknologi dan konseptual untuk *chatbot* kualitas udara berbasis LLM telah divalidasi, belum ada studi yang secara spesifik mengimplementasikan dan mengevaluasi sistem serupa dalam konteks Indonesia. Penerapan ini memerlukan adaptasi terhadap sumber data lokal, penyesuaian model untuk memahami *query* dalam Bahasa Indonesia dengan nuansa lokal, evaluasi komparatif dari arsitektur LLM yang tersedia, serta mekanisme pengendalian halusinasi agar informasi yang disampaikan selalu berlandaskan data yang sah. Kebutuhan-kebutuhan tersebut menjadi ruang kontribusi yang diisi oleh penelitian ini melalui pengembangan sistem pada dua konteks data yang berbeda karakteristiknya, yaitu data *real-time* Jawa Timur dan data historis Amerika Serikat.

2.2 Dasar Teori


Bagian ini menguraikan teori-teori penunjang yang melandasi penelitian. Pembahasan dimulai dari *Large Language Model* sebagai teknologi inti sistem, dilanjutkan dengan fenomena halusinasi beserta konsep *grounding* sebagai tantangan utama penerapannya, dua pendekatan *grounding* yang relevan yaitu *Retrieval Augmented Generation* dan pemanggilan fungsi, konsep sistem *Question Answering*, serta ditutup dengan teori domain berupa kualitas udara dan *Air Quality Index* yang menjadi objek informasi pada sistem yang dikembangkan.

2.2.1 *Large Language Model* (LLM)

Arsitektur *Transformer* yang diperkenalkan Vaswani et al. [8] menjadi landasan bagi seluruh model bahasa modern. Kemampuan model bahasa berskala besar dalam mengerjakan tugas baru tanpa pelatihan ulang ditunjukkan Brown et al. [9], sedangkan Zhao et al. [10] merangkum perkembangan dan tantangan model bahasa berskala besar secara menyeluruh. *Large Language Model* (LLM) adalah model komputasional yang dirancang untuk memahami, meringkas, menghasilkan, dan memprediksi teks serta konten lainnya berdasarkan pengetahuan yang diperoleh dari pelatihan pada *dataset* berskala masif. Fondasi arsitektur LLM modern adalah arsitektur *Transformer*. Arsitektur ini mengandalkan mekanisme *self-attention*, yang memungkinkan model untuk menimbang tingkat kepentingan setiap kata (*token*) dalam sebuah sekuens masukan saat memproses dan menghasilkan keluaran. Kemampuan ini membuat LLM sangat efektif dalam menangkap dependensi jarak jauh dan hubungan kontekstual dalam bahasa. Sebelum diproses, teks masukan dipecah menjadi unit yang lebih kecil yang disebut dengan *token* melalui proses tokenisasi. Setiap *token* kemudian direpresentasikan sebagai vektor numerik (*embedding*) yang dapat diproses oleh jaringan.

Gambar 2.1 menunjukkan skema alur kerja umum sebuah LLM. Teks masukan dari peng-

guna dipecah menjadi *token* melalui proses tokenisasi, kemudian setiap *token* diubah menjadi vektor numerik (*embedding*). Vektor-vektor tersebut diproses oleh tumpukan lapisan *Transformer* dengan mekanisme *self-attention* untuk menghasilkan prediksi *token* berikutnya. Proses ini berlangsung secara autoregresif, yaitu *token* yang baru dihasilkan ditambahkan kembali ke sekuens masukan untuk memprediksi *token* selanjutnya, hingga terbentuk teks keluaran yang utuh.



Gambar 2.1: Skema alur kerja umum *Large Language Model*

Dalam penelitian ini, dua model LLM digunakan untuk mengevaluasi efektivitas arsitektur yang dikembangkan:

- (a) Llama 3.1 [11]: Model yang dikembangkan oleh Meta AI, Llama 3.1 merupakan generasi lanjutan dari keluarga *Large Language Model Meta AI* yang berfokus pada peningkatan efisiensi, pemahaman konteks panjang, serta stabilitas respons. Model ini memiliki arsitektur *Transformer* yang telah dioptimalkan untuk mendukung *multi-turn conversation* dan *domain adaptation*, serta mendukung mekanisme pemanggilan fungsi (*tool calling*) yang menjadi landasan arsitektur sistem pada penelitian ini. Varian yang digunakan adalah Llama 3.1 8B sebagai model inti sistem.
- (b) Qwen3 [12]: Seri model *open-source* yang dikembangkan oleh Alibaba. Qwen3 memiliki kemampuan multibahasa yang luas, performa penalaran yang kuat, serta dukungan terhadap mekanisme pemanggilan fungsi (*tool calling*). Varian Qwen3 8B digunakan sebagai model pembanding pada pengujian komparatif karena memiliki jumlah parameter yang setara dengan model inti, sehingga perbandingan keduanya adil dari sisi ukuran model.

Kemampuan LLM untuk memproses data, sebagaimana yang ditunjukkan oleh Yang et al. [5], memungkinkan model ini untuk tidak hanya berperan sebagai generator teks, tetapi juga sebagai mesin analisis data. Representasi baris dan kolom data sebagai sekuens terstruktur memungkinkan LLM belajar mengidentifikasi pola dan hubungan antar-variabel.

2.2.2 Halusinasi pada LLM dan *Grounding*

Halusinasi adalah fenomena ketika LLM menghasilkan informasi yang tampak meyakinkan dan koheren secara kebahasaan, tetapi tidak didukung oleh fakta atau data yang sebenarnya [13]. Fenomena ini merupakan konsekuensi dari sifat generatif-probabilistik model bahasa: model memprediksi *token* berikutnya berdasarkan pola statistik dari data pelatihan, bukan berdasarkan

verifikasi terhadap sumber fakta. Huang et al. [14] menyusun taksonomi halusinasi beserta tantangan penanganannya, dan menegaskan bahwa halusinasi tidak dapat dihilangkan sepenuhnya melalui pelatihan model semata, sehingga diperlukan mekanisme penambatan pada sumber data eksternal. Pada domain informasi kualitas udara dan kesehatan, halusinasi menjadi risiko yang serius; misalnya, model dapat mengarang nilai indeks kualitas udara yang tidak pernah ada, sehingga berpotensi menyesatkan pengguna dalam mengambil keputusan aktivitas luar ruangan.

Grounding adalah upaya menambatkan keluaran model pada sumber data eksternal yang sah, sehingga informasi faktual dalam jawaban tidak berasal dari parameter model semata. Dua pendekatan *grounding* yang umum digunakan adalah *Retrieval Augmented Generation* (RAG) dan pemanggilan fungsi (*function calling*), yang masing-masing diuraikan pada Subbab 2.2.3 dan Subbab 2.2.4. Kedua pendekatan berbagi prinsip yang sama, yaitu memisahkan pengetahuan faktual dari parameter model, namun berbeda pada cara informasi eksternal diperoleh.

2.2.3 *Retrieval Augmented Generation (RAG)*

Retrieval Augmented Generation (RAG) yang diperkenalkan Lewis et al. [15] adalah sebuah arsitektur yang dirancang untuk meningkatkan akurasi dan keandalan respons yang dihasilkan oleh LLM dengan cara mengintegrasikan proses pengambilan informasi (*retrieval*) dari sumber data eksternal sebelum proses generasi teks. Prinsip dasar RAG adalah memisahkan pengetahuan faktual dari parameter model, sehingga respons yang dihasilkan tidak hanya bergantung pada data pra-pelatihan, melainkan diperkaya dengan konteks faktual yang relevan dan terkini. Secara umum, alur kerja RAG terdiri atas tiga tahap, yaitu pengambilan informasi relevan dari basis pengetahuan (*retrieval*), penggabungan informasi tersebut dengan *query* pengguna sebagai konteks tambahan (*augmentation*), dan penyusunan jawaban akhir oleh LLM (*generation*).

Implementasi RAG dapat bervariasi sesuai dengan karakteristik sumber data yang digunakan. Pada sistem yang mengandalkan dokumen tekstual tidak terstruktur, proses *retrieval* umumnya memanfaatkan *vector database* untuk melakukan pencarian kesamaan semantik (*semantic similarity*). Pada sistem yang sumber utamanya berupa data terstruktur, proses *retrieval* dapat dilakukan melalui kueri basis data relasional.

RAG relevan sebagai teori penunjang penelitian ini karena berbagi prinsip *grounding* yang sama dengan pendekatan yang digunakan. Penelitian ini tidak menerapkan RAG berbasis dokumen; pengambilan informasi faktual dari basis data terstruktur diwujudkan melalui mekanisme pemanggilan fungsi yang diuraikan pada Subbab 2.2.4, karena data kualitas udara yang digunakan seluruhnya bersifat terstruktur dan pemanggilan fungsi memberikan kendali yang lebih deterministik terhadap sumber data yang diakses.

2.2.4 *Pemanggilan Fungsi (Function Calling)*

Pemanggilan fungsi atau *function calling* (disebut juga *tool calling*) adalah mekanisme yang memungkinkan LLM berinteraksi dengan fungsi eksternal yang telah didefinisikan oleh pengembang. Pada mekanisme ini, setiap fungsi dideskripsikan kepada model beserta nama, kegunaan, dan parameter yang dibutuhkan. Saat menerima pertanyaan pengguna, model tidak menjalankan fungsi secara langsung, melainkan menghasilkan keluaran terstruktur berupa nama fungsi beserta argumennya berdasarkan pemahaman model terhadap maksud (*intent*) pengguna. Aplikasi kemudian mengeksekusi fungsi tersebut, misalnya dengan mengambil data dari basis

data, lalu mengembalikan hasilnya kepada model untuk disusun menjadi jawaban akhir dalam bahasa alami.

Pendekatan ini dirintis oleh Schick et al. [16] melalui Toolformer, yang menunjukkan bahwa model bahasa dapat belajar memanggil alat eksternal secara mandiri untuk memperoleh informasi yang tidak dimilikinya, dan diulas secara lebih luas oleh Qin et al. [17] dalam kajian mengenai pembelajaran penggunaan alat pada model dasar.

Mekanisme ini memberikan dua keuntungan utama bagi sistem informasi berbasis data. Pertama, pemetaan dari maksud pengguna ke aksi pengambilan data dilakukan oleh model secara fleksibel, sehingga sistem tidak memerlukan aturan deteksi maksud yang kaku dan sulit dipelihara. Kedua, seluruh informasi faktual dalam jawaban dapat dipaksa berasal dari hasil eksekusi fungsi, bukan dari pengetahuan parametrik model, sehingga risiko halusinasi terhadap data dapat ditekan. Pemanggilan fungsi menjadi mekanisme utama pengambilan data kualitas udara pada sistem yang dikembangkan dalam penelitian ini, dengan rincian arsitektur yang diuraikan pada Bab 3.

2.2.5 Sistem *Question Answering* (QA)

Sistem *Question Answering* (QA) merupakan cabang dari pemrosesan bahasa alami (NLP) yang berfokus pada pengembangan sistem yang mampu menjawab pertanyaan yang diajukan oleh manusia dalam bahasa alami. Kemunculan LLM mendorong evolusi sistem QA dari metode ekstraktif sederhana menjadi sistem generatif yang mampu memberikan jawaban dalam bentuk narasi yang koheren. *Pipeline* tipikal untuk sistem QA berbasis LLM dalam aplikasi domain spesifik, seperti kualitas udara, melibatkan beberapa tahapan: (1) *query understanding*, tahap ketika LLM menganalisis pertanyaan pengguna untuk memahami maksud (*intent*) dan entitas yang relevan; (2) *information retrieval*, tahap ketika sistem mengambil data atau dokumen yang relevan dari API *real-time* atau basis pengetahuan statis; (3) *reasoning and synthesis*, tahap ketika LLM melakukan penalaran atas informasi yang telah diambil untuk menyintesis jawaban; dan (4) *response generation*, tahap akhir ketika LLM menyusun jawaban dalam bahasa alami yang jelas dan mudah dipahami.

2.2.6 Kualitas Udara

Kualitas udara merujuk pada kondisi udara di lingkungan ambien terkait dengan kandungan polutan yang dapat memberikan dampak negatif terhadap kesehatan manusia dan lingkungan. Penilaian kualitas udara didasarkan pada pengukuran konsentrasi beberapa polutan kunci yang dikenal sebagai polutan kriteria. Polutan yang paling menjadi perhatian di wilayah urban di Jawa Timur adalah partikulat halus atau *Particulate Matter 2.5* (PM_{2.5}), yaitu partikel di udara dengan diameter aerodinamis kurang dari 2.5 mikrometer. Ukurannya yang sangat kecil memungkinkan partikel ini untuk menembus jauh ke dalam sistem pernapasan hingga ke aliran darah, sehingga berpotensi menyebabkan berbagai gangguan kardiovaskular dan pernapasan [18]. Polutan kriteria lainnya meliputi PM₁₀, Ozon (O₃), Nitrogen Dioksida (NO₂), Sulfur Dioksida (SO₂), Karbon Monoksida (CO), serta Amonia (NH₃), yang umumnya berasal dari proses pembakaran bahan bakar fosil pada sektor transportasi, industri, dan pembangkit listrik, maupun dari aktivitas pertanian dan peternakan.

Tabel 2.1 menjelaskan tentang tujuh komponen polutan udara utama yang menjadi acuan penilaian kualitas udara, beserta karakteristik, sumber, dan dampak kesehatannya secara ringkas. Empat polutan gas pada tabel tersebut, yaitu O₃, NO₂, SO₂, dan CO, menjadi polutan yang digunakan pada subsistem data historis Amerika Serikat dalam penelitian ini.

Tabel 2.1: Komponen Polutan Udara Utama

No	Komponen Polutan Udara	Keterangan Singkat
1	PM _{2.5} (Particulate Matter $\leq 2.5 \mu\text{m}$)	Partikel udara berukuran sangat halus yang dapat menembus paru-paru hingga aliran darah, umumnya berasal dari pembakaran kendaraan, industri, dan kebakaran.
2	PM ₁₀ (Particulate Matter $\leq 10 \mu\text{m}$)	Partikel udara berukuran lebih besar yang dapat menyebabkan iritasi saluran pernapasan, berasal dari debu jalan, aktivitas konstruksi, dan pembakaran.
3	O ₃ (Ozon Permukaan)	Gas reaktif yang terbentuk dari reaksi fotokimia antara nitrogen oksida dan senyawa organik volatil, berpotensi menyebabkan gangguan pernapasan.
4	NO ₂ (Nitrogen Dioksida)	Gas beracun hasil pembakaran bahan bakar fosil, terutama dari kendaraan bermotor dan industri, yang berdampak pada sistem pernapasan.
5	SO ₂ (Sulfur Dioksida)	Gas yang dihasilkan dari pembakaran bahan bakar fosil dan proses industri, dapat memperparah asma dan gangguan pernapasan.
6	CO (Carbon Monoxide)	Gas tidak berwarna dan tidak berbau yang dihasilkan dari pembakaran tidak sempurna, dapat mengurangi kemampuan darah dalam mengikat oksigen.
7	NH ₃ (Amonia)	Gas dengan bau menyengat yang umumnya berasal dari aktivitas pertanian, peternakan, dan proses industri tertentu, serta dapat membentuk partikulat sekunder di atmosfer.

2.2.7 Air Quality Index (AQI)

Sistem indeks digunakan untuk menyederhanakan komunikasi risiko kesehatan dari berbagai polutan tersebut. Secara global, sistem yang paling umum dikenal adalah *Air Quality Index* (AQI) versi *United States Environmental Protection Agency* (US EPA) [19], yang mentransformasi data konsentrasi polutan mentah (misalnya, dalam $\mu\text{g}/\text{m}^3$) menjadi sebuah angka tunggal dalam skala 0–500. Skala ini disertai dengan kategori dan kode warna yang intuitif untuk mengindikasikan tingkat risiko kesehatan, seperti Baik (Hijau), Sedang (Kuning), Tidak Sehat bagi Kelompok Sensitif (Jingga), Tidak Sehat (Merah), Sangat Tidak Sehat (Ungu), dan Berbahaya (Cokelat). Setiap kategori disertai dengan rekomendasi kesehatan spesifik, misalnya anjuran untuk mengurangi aktivitas di luar ruangan ketika level AQI mencapai kategori Tidak Sehat. Skala US EPA ini digunakan pada kedua subsistem dalam penelitian ini: penyedia data IQAir menyajikan nilai AQI dalam skala US EPA untuk subsistem Jawa Timur, sedangkan pada subsistem data historis Amerika Serikat nilai AQI dihitung sendiri dari konsentrasi mentah mengikuti standar yang sama.

Tabel 2.2 menjelaskan tentang enam kategori AQI skala US EPA beserta rentang indeks, padanan rentang konsentrasi PM_{2.5}, serta rekomendasi kesehatan pada tiap kategori. Rekomendasi kesehatan pada tabel tersebut menjadi dasar penyusunan saran tindakan preventif deterministik yang digunakan oleh sistem dalam penelitian ini.

Tabel 2.2: Kategori Air Quality Index (AQI) Skala US EPA

No	Kategori AQI	Rentang AQI	PM _{2.5} (µg/m ³)	Rekomendasi Kesehatan (Paparan 24 Jam)
1	Baik (Good)	0–50	0.0–9.0	Kualitas udara baik dan tidak menimbulkan risiko kesehatan yang signifikan. Aktivitas luar ruangan dapat dilakukan seperti biasa.
2	Sedang (Moderate)	51–100	9.1–35.4	Individu sensitif disarankan mengurangi aktivitas luar ruangan yang berat jika mengalami gejala pernapasan.
3	Tidak Sehat bagi Kelompok Sensitif	101–150	35.5–55.4	Kelompok sensitif berisiko mengalami iritasi atau gangguan pernapasan. Disarankan membatasi aktivitas luar ruangan.
4	Tidak Sehat (Unhealthy)	151–200	55.5–125.4	Masyarakat umum berpotensi mengalami gangguan kesehatan. Disarankan mengurangi aktivitas luar ruangan dalam waktu lama.
5	Sangat Tidak Sehat (Very Unhealthy)	201–300	125.5–225.4	Dampak kesehatan semakin nyata, terutama bagi kelompok sensitif. Aktivitas luar ruangan sebaiknya dibatasi secara signifikan.
6	Berbahaya (Hazardous)	≥301	≥225.5	Risiko kesehatan tinggi bagi seluruh kelompok. Disarankan menghindari aktivitas luar ruangan.

[Halaman ini sengaja dikosongkan]

BAB III

METODOLOGI

Pada bab ini akan dibahas metodologi penelitian yang digunakan, meliputi metode dan blok diagram penelitian, tahapan penelitian dari pengumpulan data hingga pengujian dan evaluasi, gambaran umum sistem yang dikembangkan, serta alat dan bahan yang digunakan.

3.1 Gambaran Umum Metodologi Penelitian

Penelitian ini menggunakan pendekatan pengembangan sistem (*system development*) yang dipadukan dengan evaluasi kuantitatif dan kualitatif untuk menilai kualitas keluaran sistem. Fokus utama penelitian adalah pengembangan sistem *chatbot* Oxyra sebagai media penyederhanaan informasi kualitas udara bagi masyarakat awam, dengan penekanan pada keakuratan informasi dan pencegahan halusinasi model bahasa. Kerangka kerja penelitian mengadopsi tahapan pengembangan sistem cerdas yang umum, sebagaimana diulas oleh Caldarini et al. [3], yang mencakup perancangan, implementasi, dan evaluasi.


Metode inti yang digunakan adalah pengembangan sistem *Question Answering* (QA) domain tertutup (*closed-domain*) yang memanfaatkan mekanisme pemanggilan fungsi (*tool calling*) pada model bahasa untuk pengambilan data secara dinamis. Melalui mekanisme ini, model bahasa tidak menjawab pertanyaan semata-mata dari pengetahuan bawaannya, melainkan memilih dan memanggil fungsi (*tool*) yang telah disediakan, sementara pengambilan data dan seluruh perhitungan numerik dilakukan sepenuhnya oleh kode program secara deterministik. Prinsip pemisahan ini—*kode yang mengambil dan menghitung data, model bahasa yang merangkai jawaban*—menjadi landasan utama strategi anti-halusinasi pada penelitian ini. Pendekatan penggunaan LLM untuk memicu pengambilan dan analisis data dari sumber terstruktur terinspirasi oleh implementasi VayuBuddy [6], sedangkan kelayakan LLM dalam memproses data terstruktur didasarkan pada temuan Yang et al. [5].

Sistem dikembangkan pada dua subsistem data yang saling melengkapi untuk menguji ketahanan pendekatan ini pada karakteristik data yang berbeda, yaitu subsistem kualitas udara *real-time* untuk wilayah Jawa Timur dan subsistem data historis untuk wilayah Amerika Serikat berbasis standar *United States Environmental Protection Agency* (US EPA). Kedua subsistem menggunakan skala *Air Quality Index* (AQI) US yang sama serta arsitektur *tool calling* dan strategi anti-halusinasi yang identik, sehingga perbandingan yang dilakukan berfokus pada konsistensi pendekatan dalam menangani karakteristik data yang berbeda, bukan pada perbandingan nilai antarwilayah yang memang tidak setara.

3.1.1 Blok Diagram Penelitian

Secara garis besar, alur penelitian ini terdiri atas empat tahap utama yang dilakukan secara berurutan, yaitu *input*, ekstraksi, *preprocessing*, serta *output* dan validasi. Gambar 3.1 menunjukkan blok diagram penelitian beserta komponen pada tiap tahapnya. Tahap *input* mencakup tiga masukan sistem, yaitu data IQAir API, data historis US EPA, dan pertanyaan pengguna dalam bahasa alami. Tahap ekstraksi mencakup penguraian respons API serta perhitungan AQI dari konsentrasi mentah. Tahap *preprocessing* terdiri atas dua jalur, yaitu jalur data (struktur-

isasi dan penyimpanan basis data) dan jalur pertanyaan (gerbang anti-halusinasi dan penguraian pertanyaan majemuk). Tahap *output* dan validasi mencakup penyusunan jawaban oleh model bahasa serta pengujian dan evaluasi sistem.



Gambar 3.1: Blok Diagram Penelitian

3.2 Tahapan Penelitian

Bagian ini menguraikan secara lebih rinci keempat tahapan yang digambarkan pada blok diagram penelitian. Tahap *input* diuraikan pada Subbab 3.2.1 mengenai pengumpulan data. Tahap ekstraksi diuraikan pada Subbab 3.2.2 mengenai ekstraksi data dari respons API dan Subbab 3.2.4 mengenai perhitungan AQI. Tahap *preprocessing* diuraikan pada Subbab 3.2.3 mengenai pemrosesan awal data untuk jalur data, serta Subbab 3.2.6 mengenai arsitektur anti-halusinasi untuk jalur pertanyaan. Tahap *output* dan validasi diuraikan pada Subbab 3.2.5 mengenai pengembangan sistem *chatbot* hingga Subbab 3.2.10 mengenai pengujian dan evaluasi.

3.2.1 Pengumpulan Data

Tahap pengumpulan data berfokus pada perolehan seluruh masukan sistem sebagaimana tahap *input* pada blok diagram, yaitu data kualitas udara dari dua sumber yang merepresentasikan dua karakteristik berbeda, serta pertanyaan pengguna dalam bahasa alami.

(a) **Data *Real-time* Jawa Timur (IQAir).**

Data kualitas udara *real-time* diperoleh dari *IQAir API* untuk 16 kota di Jawa Timur. Sebuah modul *data collector* berbasis Python dijalankan secara periodik setiap dua jam untuk mengambil kondisi terkini tiap kota. Setiap pembacaan menghasilkan nilai AQI US, kode polutan dominan, serta parameter cuaca berupa suhu, kelembaban, tekanan udara, dan kecepatan angin. Data ini disimpan secara akumulatif sehingga membentuk riwayat historis yang digunakan untuk analisis pola jangka pendek. Berbeda dengan sumber berbasis model prakiraan, IQAir menyediakan indeks kualitas udara dan polutan dominan hasil pemantauan, namun tidak menyediakan konsentrasi mentah tiap polutan dalam satuan $\mu\text{g}/\text{m}^3$.

(b) **Data Historis Amerika Serikat (US EPA).**

Data historis diperoleh dari basis data pemantauan kualitas udara US EPA untuk empat polutan gas, yaitu ozon (O_3), nitrogen dioksida (NO_2), sulfur dioksida (SO_2), dan karbon monoksida (CO). Dataset ini berisi konsentrasi mentah tiap polutan dalam satuan aslinya (ppm dan ppb) sebanyak $[\pm 2,8 \text{ juta}]$ baris. Nilai AQI tidak diperoleh secara langsung, melainkan dihitung sendiri dari konsentrasi mentah menggunakan rumus interpolasi linear EPA (dijelaskan pada Subbab 3.2.4). Ketersediaan konsentrasi mentah pada data ini memungkinkan sistem menyajikan informasi yang lebih rinci dibandingkan data *real-time* Jawa Timur, sekaligus menjadi pembanding dalam menguji konsistensi pendekatan sistem.

(c) **Pertanyaan Pengguna.**

Masukan ketiga sistem adalah pertanyaan pengguna dalam Bahasa Indonesia yang diajukan melalui antarmuka *chatbot*. Pertanyaan bersifat bahasa alami dengan gaya yang beragam, sehingga sistem harus mampu memahami maksud pengguna sekaligus menyaring pertanyaan yang berada di luar lingkup data. Kumpulan pertanyaan nyata dari masyarakat awam yang digunakan untuk pengujian dikumpulkan melalui kuesioner, dengan desain yang diuraikan pada Subbab 3.2.10.

Kedua subsistem tidak dibandingkan secara langsung dari sisi nilai kualitas udara karena berbeda polutan, wilayah, dan periode. Perbandingan difokuskan pada konsistensi arsitektur dan strategi anti-halusinasi dalam menangani dua karakteristik data yang berbeda, dengan skala AQI US sebagai kerangka yang menyatukan keduanya.

3.2.2 Ekstraksi Data dari Respons API

Data yang diterima dari sumber tidak dapat langsung digunakan karena masih berbentuk struktur mentah yang memuat banyak informasi yang tidak diperlukan sistem. Tahap ekstraksi bertugas menguraikan struktur tersebut dan mengambil hanya nilai-nilai yang relevan, sehingga data yang diteruskan ke tahap berikutnya sudah berbentuk terstruktur dan seragam. Tahap ini merupakan blok ekstraksi pada blok diagram penelitian.

Respons dari *IQAir API* diterima dalam format JSON yang bersifat bersarang, yaitu nilai-nilai yang dibutuhkan tersimpan di dalam beberapa lapis objek. Penguraian dilakukan dengan menelusuri lapisan tersebut untuk mengambil empat kelompok nilai, yaitu nilai AQI standar US, kode polutan dominan, parameter cuaca berupa suhu, kelembaban, tekanan udara, dan kecepatan angin, serta stempel waktu pengukuran. Kode polutan dominan yang diterima berupa singkatan teknis, misalnya p2 untuk PM_{2.5}, sehingga pada tahap ini kode tersebut diterjemahkan menjadi penamaan yang dikenali pengguna.

Penguraian pada subsistem US EPA berbeda karena data tidak diterima melalui *API* tunggal, melainkan berupa berkas data pengukuran yang memuat kolom-kolom baku US EPA. Ekstraksi dilakukan dengan mengambil kolom identitas lokasi, yaitu negara bagian, *county*, dan kode stasiun; kolom waktu pengukuran; serta kolom konsentrasi polutan beserta satuannya. Berbeda dengan subsistem Jawa Timur yang menerima nilai AQI dalam keadaan sudah dihitung, subsistem US EPA hanya menerima konsentrasi mentah, sehingga hasil ekstraksi pada subsistem ini masih memerlukan perhitungan AQI sebagaimana diuraikan pada Subbab 3.2.4.

Tabel 3.1 menjelaskan tentang perbandingan nilai yang dihasilkan tahap ekstraksi pada kedua subsistem.

Tabel 3.1: Nilai Hasil Ekstraksi pada Kedua Subsistem

Aspek	Subsistem Jawa Timur	Subsistem US EPA
Bentuk sumber	Respons JSON bersarang dari <i>API</i>	Berkas data pengukuran berkolom baku
Identitas lokasi	Nama kota	Negara bagian, <i>county</i> , kode stasiun
Nilai kualitas udara	AQI standar US (sudah dihitung sumber)	Konsentrasi mentah polutan (ppm/ppb)
Informasi polutan	Kode polutan dominan	Jenis polutan sesuai berkas
Parameter cuaca	Suhu, kelembaban, tekanan, kecepatan angin	Tidak tersedia
Kebutuhan lanjutan	Langsung dapat digunakan	Memerlukan perhitungan AQI

Tabel 3.1 menunjukkan bahwa perbedaan mendasar kedua subsistem sudah muncul sejak tahap ekstraksi. Subsistem Jawa Timur menerima indeks yang telah dihitung oleh penyedia data, sehingga sistem tidak memiliki akses terhadap konsentrasi mentah tiap polutan. Subsistem US EPA sebaliknya menerima konsentrasi mentah tanpa indeks, sehingga sistem harus menghitung sendiri nilai AQI-nya. Perbedaan inilah yang menyebabkan pertanyaan mengenai nilai polutan spesifik dapat dijawab pada subsistem US EPA namun ditolak pada subsistem

Jawa Timur, dan penolakan tersebut bukan merupakan kegagalan sistem melainkan konsekuensi cakupan data yang telah diketahui sejak tahap ekstraksi.

Tahap ekstraksi juga menangani kemungkinan nilai yang tidak lengkap. Apabila suatu bidang yang dibutuhkan tidak ditemukan pada respons, misalnya karena *API* sedang tidak mengembalikan nilai tertentu, pembacaan tersebut ditandai sebagai tidak lengkap dan tidak diteruskan ke tahap penyimpanan. Penanganan ini penting untuk menjaga agar basis data tidak terisi nilai kosong yang berpotensi menghasilkan jawaban keliru pada tahap berikutnya.

3.2.3 Pemrosesan Awal Data

Data mentah yang terkumpul tidak langsung dapat digunakan, sehingga melalui tahap pemrosesan awal terlebih dahulu. Tahap ini merupakan jalur data pada tahap *preprocessing* blok diagram dan penting untuk menjamin konsistensi dan keandalan data yang menjadi dasar jawaban sistem.

Pemrosesan awal pada subsistem *real-time* Jawa Timur meliputi beberapa langkah. Pertama, penyeragaman penamaan kota agar variasi penulisan yang mungkin muncul dari sumber data merujuk pada entitas kota yang sama. Kedua, penanganan pembacaan yang gagal atau kosong, misalnya ketika *API* tidak mengembalikan nilai pada suatu siklus pengambilan, sehingga data yang tidak lengkap tidak ikut tersimpan. Ketiga, penyimpanan riwayat secara konsisten pada setiap siklus dua jam, dengan mencatat waktu pengambilan agar dapat digunakan untuk analisis pola historis.

Pemrosesan awal pada subsistem historis US EPA berfokus pada penyiapan data konsentrasi mentah sebelum perhitungan AQI. Langkah ini meliputi pembersihan nilai yang tidak valid atau di luar rentang wajar, penyelarasan satuan tiap polutan sesuai ketentuan EPA (ppm untuk O_3 dan CO, ppb untuk NO_2 dan SO_2), serta pengelompokan data per polutan. Pengelompokan per polutan ini memudahkan perhitungan sub-indeks masing-masing polutan secara independen sebelum ditentukan nilai AQI akhir sebagai nilai tertinggi di antara seluruh sub-indeks. Seluruh data hasil pemrosesan disimpan pada basis data MySQL sebagai sumber utama sistem.

3.2.4 Perhitungan AQI

Nilai AQI pada penelitian ini mengikuti standar US EPA. Nilai AQI pada subsistem Jawa Timur diperoleh langsung dari IQAir, sedangkan pada subsistem US EPA nilai AQI dihitung sendiri dari konsentrasi mentah tiap polutan. Persamaan 3.1 menunjukkan rumus interpolasi linear *piecewise* yang digunakan untuk perhitungan tersebut, sebagaimana didefinisikan US EPA [19].

$$I_p = \frac{I_{Hi} - I_{Lo}}{BP_{Hi} - BP_{Lo}} (C_p - BP_{Lo}) + I_{Lo} \quad (3.1)$$

dengan I_p adalah indeks (AQI) untuk polutan p , C_p adalah konsentrasi polutan hasil pembulatan sesuai ketentuan, BP_{Lo} dan BP_{Hi} adalah batas bawah dan batas atas *breakpoint* konsentrasi yang memuat C_p , serta I_{Lo} dan I_{Hi} adalah nilai indeks yang bersesuaian dengan kedua *breakpoint* tersebut. Nilai AQI akhir suatu lokasi ditetapkan sebagai nilai indeks tertinggi di antara seluruh polutan yang dihitung (*dominant pollutant*).

Kategori kualitas udara ditentukan berdasarkan rentang nilai AQI sesuai standar EPA. Tabel 3.2 menjelaskan tentang enam kategori kualitas udara beserta rentang nilai AQI masing-masing, yang menjadi dasar interpretasi kondisi udara oleh sistem.

Tabel 3.2: Kategori Kualitas Udara Berdasarkan Nilai AQI (US EPA)

Rentang AQI	Kategori
0–50	Baik (<i>Good</i>)
51–100	Sedang (<i>Moderate</i>)
101–150	Tidak Sehat bagi Kelompok Sensitif
151–200	Tidak Sehat (<i>Unhealthy</i>)
201–300	Sangat Tidak Sehat (<i>Very Unhealthy</i>)
301–500	Berbahaya (<i>Hazardous</i>)

Perhitungan sub-indeks tiap polutan menggunakan tabel *breakpoint* yang telah ditetapkan EPA. Tabel 3.3 menjelaskan tentang sebagian *breakpoint* untuk polutan yang digunakan pada subsistem US EPA [19], yaitu batas konsentrasi tiap kategori yang menjadi acuan interpolasi. Konsentrasi yang terukur dipetakan ke rentang *breakpoint* yang memuatnya, kemudian nilai sub-indeks dihitung melalui interpolasi linear sebagaimana Persamaan 3.1.

Tabel 3.3: Contoh *Breakpoint* Konsentrasi dan Indeks AQI (US EPA)

Kategori	Indeks ($I_{Lo}-I_{Hi}$)	O ₃ 8-jam (ppm)	CO 8-jam (ppm)
Baik	0–50	0,000–0,054	0,0–4,4
Sedang	51–100	0,055–0,070	4,5–9,4
Tidak Sehat Sensitif	101–150	0,071–0,085	9,5–12,4
Tidak Sehat	151–200	0,086–0,105	12,5–15,4

Ilustrasi perhitungannya adalah sebagai berikut. Apabila konsentrasi ozon 8-jam terukur sebesar 0,078 ppm, maka nilai tersebut berada pada rentang kategori “Tidak Sehat bagi Kelompok Sensitif” ($BP_{Lo} = 0,071$; $BP_{Hi} = 0,085$; $I_{Lo} = 101$; $I_{Hi} = 150$). Persamaan 3.1 menghasilkan:

$$I_p = \frac{150 - 101}{0,085 - 0,071} (0,078 - 0,071) + 101 \approx 125 \quad (3.2)$$


sehingga sub-indeks ozon bernilai sekitar 125. Nilai AQI akhir lokasi tersebut kemudian ditetapkan sebagai nilai tertinggi di antara seluruh sub-indeks polutan yang dihitung.

3.2.5 Pengembangan Sistem Chatbot

Pada tahap ini dikembangkan inti sistem Oxyra. Pengembangan mencakup *backend* berbasis FastAPI yang berperan sebagai orkestrator utama, yang mengoordinasikan alur antara pertanyaan pengguna, pemanggilan fungsi, pengambilan data, dan penyusunan jawaban oleh model bahasa. Komponen utama yang dikembangkan adalah sebagai berikut.

- Mekanisme Tool Calling.** Model bahasa diberikan sekumpulan definisi fungsi (*tool*), seperti pengambilan kondisi satu kota, kondisi seluruh kota, peringkat kualitas udara antarkota, dan analisis pola historis. Ketika menerima pertanyaan, model memilih fungsi yang sesuai beserta argumennya, kemudian kode program menjalankan fungsi tersebut untuk mengambil data. Model bahasa tidak pernah menghasilkan nilai numerik secara

mandiri; seluruh angka berasal dari hasil pemanggilan fungsi. Pendekatan ini menggantikan pengembangan awal yang sempat menggunakan deteksi maksud (*intent detection*) berbasis kata kunci, karena *tool calling* terbukti lebih fleksibel dalam menangani variasi bahasa alami sekaligus tetap menjaga determinisme pada bagian pengambilan data. Gambar 3.2 menunjukkan alur mekanisme *tool calling* tersebut, mulai dari pertanyaan pengguna, pemilihan fungsi oleh model, eksekusi fungsi oleh kode program, hingga penyusunan jawaban akhir.



Gambar 3.2: Alur Mekanisme *Tool Calling*

- (b) **Modul Pengambilan Data (*Tools*).** Berdasarkan fungsi yang dipanggil model, modul ini menyusun dan menjalankan kueri ke basis data atau permintaan ke *API* untuk memperoleh data kualitas udara yang relevan, baik kondisi terkini, peringkat antarkota, maupun pola historis.
- (c) **Mekanisme Saran Kesehatan Deterministik.** Saran tindakan kesehatan tidak diserahkan sepenuhnya kepada model bahasa, melainkan ditetapkan secara deterministik oleh kode berdasarkan kategori AQI. Rumusan saran ini merupakan parafrase dari *cautionary statements* resmi US EPA. Model bahasa hanya bertugas merangkai saran tersebut menjadi bahasa yang mudah dipahami, tanpa mengubah substansinya.
- (d) **Integrasi Model Bahasa.** Model bahasa lokal dijalankan melalui Ollama dan menerima konteks berupa data terstruktur hasil pemanggilan fungsi untuk menghasilkan jawaban

dalam bahasa alami. Model inti yang digunakan adalah Llama3.1 8B dengan parameter *temperature* rendah dan *seed* tetap untuk menjaga konsistensi keluaran.


- (e) **Dukungan *Multi-turn Conversation*.** Sistem mendukung percakapan berlanjut sehingga pengguna dapat mengajukan pertanyaan lanjutan secara kontekstual.

3.2.6 Arsitektur Anti-Halusinasi

Pencegahan halusinasi menjadi kebutuhan utama karena sistem ditujukan untuk menyampaikan informasi kesehatan kepada masyarakat awam. Halusinasi didefinisikan sebagai keadaan ketika model bahasa menghasilkan informasi yang tidak didukung oleh data sistem, misalnya menyebutkan angka atau fakta yang tidak dimiliki sistem. Strategi anti-halusinasi berlapis dirancang untuk mengatasinya sebagai berikut.

- (a) **Pemisahan Angka dari Model.** Seluruh nilai numerik berasal dari kode program melalui pemanggilan fungsi; model bahasa hanya merangkai kata. Pemisahan ini menutup kesempatan model untuk mengarang nilai kualitas udara.
- (b) **Gerbang Pertanyaan di Luar Lingkup.** Pertanyaan yang menyangkut data yang tidak dimiliki sistem—seperti kadar oksigen, konsentrasi $\mu g/m^3$, persentase polusi, prediksi masa depan, kualitas udara dalam ruangan, atau kebijakan tata ruang—dideteksi dan ditolak secara sopan sebelum diproses oleh model bahasa, sehingga model tidak mengarang jawaban.
- (c) **Validasi Wilayah.** Ketika pengguna menyebut lokasi yang tidak spesifik (misalnya “daerah saya”), sistem tidak mengarang nama kota, melainkan meminta pengguna menyebutkan kota yang dimaksud.
- (d) **Penguraian Pertanyaan Majemuk.** Pertanyaan yang memuat beberapa maksud sekaligus diuraikan menjadi bagian-bagian terpisah. Bagian yang dapat dijawab diproses, sedangkan bagian yang di luar lingkup ditolak, kemudian seluruh hasil dirangkai menjadi satu jawaban yang mengalir.
- (e) **Penanganan Kegagalan Data.** Apabila data yang diminta tidak ditemukan, sistem menyampaikannya secara jujur dan tidak melanjutkan dengan kondisi yang dikarang.

Keseluruhan lapisan tersebut bekerja secara berurutan membentuk sebuah alur penyaringan. Ketika sebuah pertanyaan masuk, sistem terlebih dahulu memeriksa apakah pertanyaan berada di luar lingkup data; apabila ya, pertanyaan langsung ditolak secara sopan. Apabila lolos, sistem memeriksa apakah lokasi yang disebut cukup spesifik; apabila tidak, sistem meminta pengguna menyebutkan kota. Pertanyaan yang memuat beberapa maksud kemudian diuraikan, dan hanya bagian yang berada dalam lingkup yang diteruskan untuk pemanggilan fungsi. Setelah data diperoleh, apabila seluruh pemanggilan gagal, sistem menyampaikannya secara jujur tanpa mengarang kondisi. Barulah pada tahap akhir, model bahasa merangkai fakta yang telah terkumpul menjadi jawaban. Alur berlapis ini memastikan bahwa model bahasa hanya menerima pertanyaan dan data yang benar-benar dapat dipertanggungjawabkan. Gambar 3.3 menunjukkan alur penyaringan anti-halusinasi tersebut, mulai dari pemeriksaan lingkup pertanyaan hingga perangkaian jawaban akhir oleh model bahasa.



Gambar 3.3: Alur Penyaringan Anti-Halusinasi

3.2.7 Analisis Pola Historis

Riwayat data yang terkumpul secara berkala dimanfaatkan untuk analisis pola jangka pendek. Analisis ini bertujuan menjawab pertanyaan masyarakat yang berkaitan dengan waktu, seperti “jam berapa udara biasanya paling baik” atau “apakah kondisi cenderung membaik atau memburuk”, tanpa terjebak pada peramalan yang tidak didukung data.

Analisis pola dilakukan pada dua tingkatan. Tingkat pertama adalah pola per periode waktu, yaitu subuh, pagi, siang, sore, dan malam, dengan menghitung rata-rata nilai AQI historis pada tiap periode. Tingkat kedua adalah pola per hari dalam seminggu. Sistem menerapkan ambang kebermaknaan untuk menjaga kejujuran informasi: suatu pola hanya dinyatakan apabila selisih antarwaktu cukup berarti. Apabila selisihnya kecil, sistem menyampaikan bahwa kondisi relatif stabil, alih-alih memaksakan kesimpulan dari perbedaan yang tidak signifikan. Khusus untuk pola per hari, kesimpulan hanya dinyatakan apabila data telah terkumpul dalam rentang minggu yang memadai, mengingat perbedaan antarhari memerlukan jumlah pengamatan yang lebih banyak untuk dapat dianggap konsisten.

Hal terpenting dalam analisis ini adalah pembungkahan. Seluruh keluaran analisis pola disampaikan sebagai gambaran berdasarkan pola historis, bukan sebagai prediksi. Pertanyaan yang menyangkut kondisi mendatang dijawab dengan penegasan eksplisit bahwa sistem tidak dapat memastikan kondisi pada waktu tertentu di masa depan, kemudian pola beberapa hari terakhir disajikan sebagai bahan pertimbangan. Pembungkahan ini menjaga konsistensi dengan strategi anti-halusinasi, yaitu sistem tidak menyampaikan informasi yang melampaui dukungan

datanya.

3.2.8 Deployment pada VPS

Komponen pengumpul data dan layanan *API* di-deploy pada sebuah *Virtual Private Server* (VPS) dengan sistem operasi Ubuntu [24.04] agar pengumpulan data *real-time* berlangsung secara berkelanjutan dan tidak bergantung pada perangkat pengembang. Arsitektur *deployment* dirancang agar setiap komponen berjalan mandiri dan pulih otomatis.

Komponen pertama adalah modul pengumpul data (*collector*) yang dijalankan secara terjadwal setiap dua jam menggunakan *cron*. Pada setiap eksekusi, modul ini mengambil kondisi terkini seluruh kota, melakukan pemrosesan awal, lalu menyimpannya ke basis data sebagai riwayat. Komponen kedua adalah layanan *API* yang dijalankan secara permanen sebagai *systemd service*. Layanan ini menyediakan *endpoint* yang dapat diakses sistem untuk memperoleh kondisi terkini, riwayat, maupun data seluruh kota. Penggunaan *systemd* memastikan layanan otomatis berjalan kembali apabila terjadi gangguan atau *restart* server.

Konfigurasi ini membuat riwayat data terbentuk secara konsisten selama periode penelitian dan menjadi dasar bagi analisis pola historis. Pemisahan antara proses pengumpulan terjadwal dan layanan penyedia data juga membuat sistem lebih andal, karena kegagalan pada salah satu komponen tidak langsung menghentikan komponen lainnya.

3.2.9 Integrasi Frontend dan Backend

Antarmuka pengguna (*frontend*) dibangun menggunakan React dengan TypeScript serta *build tool* Vite, dan ditata menggunakan Tailwind CSS. Antarmuka ini bertugas menerima masukan pertanyaan dari pengguna, menampilkan respons dalam bentuk teks maupun visualisasi grafik, serta mengelola riwayat percakapan agar interaksi terasa berkelanjutan.

Komunikasi antara *frontend* dan *backend* dilakukan melalui antarmuka REST yang disediakan oleh FastAPI. Ketika pengguna mengirim pertanyaan, *frontend* meneruskannya ke *backend*, yang kemudian menjalankan seluruh alur pemrosesan, mulai dari pemeriksaan anti-halusinasi, pemanggilan fungsi oleh model bahasa, pengambilan data, hingga penyusunan jawaban. Jawaban akhir beserta data pendukung untuk visualisasi dikirim kembali ke *frontend* untuk ditampilkan. Pemisahan yang jelas antara *frontend* sebagai lapisan penyajian dan *backend* sebagai lapisan pemrosesan membuat sistem lebih mudah dikembangkan dan diuji secara terpisah.

3.2.10 Pengujian dan Evaluasi

Pengujian dilakukan melalui dua jalur yang saling melengkapi, yaitu validasi akurasi terhadap basis data pada subsistem US EPA dan pengujian persepsi awam pada subsistem *real-time* Jawa Timur.

- (a) **Validasi Akurasi terhadap Basis Data.** Pada subsistem US EPA, jawaban sistem diuji terhadap nilai acuan (*ground truth*) yang dihitung langsung dari basis data melalui sejumlah pertanyaan validasi. Pengujian ini menilai apakah nilai yang disampaikan sistem sesuai dengan data sebenarnya.
- (b) **Pengujian Persepsi Awam.** Pengujian pada subsistem *real-time* Jawa Timur difokuskan pada kesesuaian jawaban terhadap pertanyaan masyarakat awam. Metode ini menekankan bahwa yang dinilai bukan sekadar ketepatan angka, melainkan sejauh mana jawaban sistem membantu masyarakat awam memahami kondisi udara dan mengambil tindakan.

- (c) **Pengujian Kepuasan Responden.** Sebagai pelengkap penilaian ahli, dilakukan pengujian kepuasan responden untuk mengukur preferensi masyarakat awam terhadap jawaban sistem Oxyra dibandingkan jawaban model bahasa yang sama ketika dijalankan secara mentah tanpa arsitektur Oxyra. Pengujian menggunakan desain perbandingan berpasangan tersamar (*blind A/B*): responden disajikan empat pasangan jawaban atas pertanyaan yang identik, masing-masing berlabel Jawaban A dan Jawaban B tanpa keterangan sistem yang menghasilkannya, kemudian diminta memilih jawaban yang lebih disukai pada tiap pasangan. Kedua jawaban pada tiap pasangan dihasilkan oleh model dasar yang sama, yaitu Llama 3.1 8B, sehingga perbedaan yang dinilai responden sepenuhnya mencerminkan kontribusi arsitektur, sejalan dengan perbandingan pada Subbab 4.5. Kuesioner diisi oleh 10 responden, dan hasil dianalisis sebagai jumlah pemilihan tiap jawaban pada setiap pasangan.

Desain instrumen pengujian persepsi awam disusun sebagai berikut. Pertanyaan dikumpulkan melalui kuesioner daring kepada 40 responden dengan latar belakang beragam. Responden diminta menuliskan pertanyaan dengan bahasa mereka sendiri, seolah bertanya kepada seorang teman mengenai kondisi udara. Kuesioner terdiri atas tiga bagian, yaitu pertanyaan pembuka spontan, pertanyaan lanjutan pada konteks udara baik (Malang), dan pertanyaan lanjutan pada konteks udara kurang sehat (Singosari). Pertanyaan yang terkumpul kemudian dikelompokkan berdasarkan kesamaan maksud untuk memperoleh sejumlah pertanyaan yang representatif, sekaligus mengidentifikasi jenis pertanyaan yang berada di luar lingkup sistem.

Pemilihan pertanyaan yang dinilai oleh ahli dilakukan menggunakan teknik pengambilan sampel bertujuan (*purposive sampling*), yaitu pemilihan berdasarkan kriteria keterwakilan maksud dan bukan pemilihan acak. Kriteria yang ditetapkan adalah bahwa pertanyaan terpilih secara bersama-sama harus mewakili seluruh jalur pemrosesan sistem, yaitu pertanyaan kondisi terkini, pertanyaan edukatif, pertanyaan dengan lokasi tidak spesifik, pertanyaan di luar lingkup data, serta pertanyaan majemuk. Pemilihan acak tidak digunakan karena berpeluang menghasilkan sampel yang seluruhnya berupa pertanyaan sejenis, sehingga sebagian jalur sistem, khususnya lapisan anti-halusinasi, berpotensi tidak teruji sama sekali. Tujuan penilaian ahli pada penelitian ini bukan generalisasi statistik, melainkan pengujian keterwakilan fungsi sistem.

Pertanyaan representatif diujikan ke sistem dengan tetap mempertahankan gaya bahasa asli responden, dan jawaban sistem dicatat. Jawaban sistem selanjutnya dinilai oleh ahli menggunakan skala 5 hingga 10, dengan 5 menyatakan jawaban sangat kurang dan 10 menyatakan jawaban sangat baik, kemudian skor dirata-ratakan. Penilaian dilakukan oleh validator ahli independen yang tidak terlibat dalam pengembangan sistem. Hasil pengujian beserta analisisnya diuraikan pada Bab 4.

Gambar 3.4 menunjukkan tampilan kuesioner daring yang digunakan untuk mengumpulkan pertanyaan dari responden, yang memuat identitas dan rentang usia responden serta instruksi yang meminta responden membayangkan aplikasi sebagai teman yang dapat ditanyai soal udara di sekitarnya, sehingga pertanyaan yang terkumpul mencerminkan gaya bahasa alami masyarakat awam. Bagian ini ditampilkan karena pertanyaan yang terkumpul darinya menjadi sumber pertanyaan representatif yang diujikan ke sistem dan dinilai oleh ahli.

Kuesioner Kualitas Udara

Tolong Bantu Saya Mengumpulkan Pertanyaan Seputar Udara di Sekitar Kita

Halo! Saya sedang membuat sebuah aplikasi yang bisa memberi informasi tentang kondisi udara di berbagai daerah di Jawa Timur – misalnya apakah udara di suatu kota sedang bersih, kurang sehat, atau aman untuk beraktivitas di luar.

* Indicates required question

Nama Lengkap *

Usia *


☐ < 20
 ☐ 20 - 35
 ☐ 36 - 50
 ☐ > 50

Bayangkan aplikasi ini seperti teman yang bisa Anda tanyai soal udara di sekitar Anda. Kira-kira, apa yang ingin Anda tanyakan kepadanya? *

Tidak ada jawaban benar atau salah – tuliskan saja dengan bahasa Anda sendiri, seperti saat Anda bertanya ke teman. Boleh tentang aktivitas harian, kesehatan, cuaca, atau apa pun yang terlintas soal udara. (boleh lebih dari satu pertanyaan)

Gambar 3.4: Tampilan Kuesioner Daring Pengumpulan Pertanyaan

Gambar 3.5 menunjukkan alur pengujian persepsi awam tersebut secara keseluruhan, mulai dari pengumpulan pertanyaan melalui kuesioner, pengelompokan berdasarkan kesamaan maksud, pengujian ke sistem, penilaian oleh ahli, hingga analisis hasil.



Gambar 3.5: Alur Pengujian Persepsi Awam


Perbandingan dua model LLM lokal, yaitu Llama 3.1 8B sebagai model inti dan Qwen3 8B sebagai model pembanding, dilakukan pada *pipeline* yang sama sebagai pelengkap untuk menilai kesesuaian model inti yang dipilih. Rincian pengujian dan hasilnya diuraikan pada Bab 4.

3.3 Gambaran Umum Sistem

Sistem yang dikembangkan adalah Oxyra, yaitu sebuah *chatbot* berbasis *Large Language Model* (LLM) yang dirancang untuk menyederhanakan informasi kualitas udara bagi

masyarakat awam. Sistem mengintegrasikan data kualitas udara dari IQAir (Jawa Timur, *real-time*) dan US EPA (Amerika Serikat, historis) dengan model bahasa generatif yang dijalankan secara lokal melalui Ollama, sehingga mampu menghasilkan jawaban yang informatif, kontekstual, dan mudah dipahami, dengan tetap menjaga keakuratan melalui strategi anti-halusinasi.

Oxyra secara umum berfungsi sebagai perantara antara data kualitas udara dan pengguna. Sistem tidak hanya menampilkan nilai numerik seperti AQI, tetapi juga menerjemahkannya menjadi penjelasan yang mudah dipahami serta memberikan saran tindakan yang sesuai dengan kondisi kualitas udara. Gambar 3.6 menunjukkan arsitektur sistem Oxyra yang terdiri atas tiga lapisan utama, yaitu lapisan *frontend*, lapisan *backend*, dan lapisan model bahasa.



Gambar 3.6: Arsitektur Sistem Oxyra

- (a) **Lapisan *Frontend*.** Antarmuka pengguna berbasis React dengan TypeScript yang bertugas menerima pertanyaan, menampilkan respons, serta mengelola riwayat percakapan.
- (b) **Lapisan *Backend*.** Lapisan inti berbasis FastAPI yang berperan sebagai orkestrator. Lapisan ini menerima pertanyaan dari *frontend*, menerapkan lapisan anti-halusinasi (gerbang luar-lingkup, validasi wilayah, dan penguraian pertanyaan majemuk), memfasilitasi pemanggilan fungsi oleh model bahasa, mengambil data yang relevan, kemudian menyusun konteks yang diteruskan kembali ke model bahasa untuk dirangkai menjadi jawaban.
- (c) **Lapisan Model Bahasa.** Lapisan yang menjalankan model LLM secara lokal melalui Ollama. Lapisan ini menerima konteks berisi data hasil pemanggilan fungsi dan menghasilkan jawaban akhir dalam bahasa alami.

Alur kerja sistem dimulai ketika pengguna mengirimkan pertanyaan melalui *frontend*. Pertanyaan diteruskan ke *backend*, yang terlebih dahulu memeriksanya melalui lapisan anti-halusinasi. Apabila pertanyaan berada dalam lingkup dan spesifik, model bahasa memilih fungsi yang sesuai, lalu kode program mengambil data terkait. Data tersebut disusun sebagai konteks dan diteruskan kembali ke model bahasa untuk dirangkai menjadi jawaban, yang akhirnya dikirim ke *frontend* untuk ditampilkan kepada pengguna.

3.4 Alat dan Bahan

Pengembangan sistem Oxyra memanfaatkan berbagai perangkat keras dan perangkat lunak yang saling terintegrasi untuk mendukung akuisisi data, pemrosesan informasi, inferensi model bahasa, serta evaluasi kinerja sistem.

3.4.1 Perangkat Keras

Perangkat keras yang digunakan pada penelitian ini adalah sebagai berikut.

1. **Komputer Pengembang (*Development Machine*).**

Berfungsi sebagai lingkungan utama pengembangan sistem, mulai dari pengolahan data, pengembangan *backend* dan *frontend*, hingga eksekusi dan pengujian model bahasa. Spesifikasi yang digunakan:

- Prosesor: x86-64 (Intel/AMD)
- Memori: 32 GB RAM
- Penyimpanan: SSD 1 TB
- Sistem Operasi: Windows 11

2. **Virtual Private Server (VPS).**

Digunakan untuk menjalankan pengumpulan data *real-time* dan layanan *API* secara berkelanjutan. Spesifikasi:

- Sistem Operasi: Ubuntu [24.04]
- Peran: Menjalankan *collector* (terjadwal via *cron*) dan layanan *API* (*systemd service*)

3. **Perangkat Jaringan (*Internet Access*).**

Digunakan untuk mengakses *API* kualitas udara eksternal, mengunduh model LLM melalui Ollama, serta komunikasi antara *frontend*, *backend*, dan VPS.

3.4.2 Perangkat Lunak

Perangkat lunak yang digunakan pada penelitian ini adalah sebagai berikut.

1. **Sistem Operasi.**

Windows 11 digunakan pada komputer pengembang, sedangkan Ubuntu [24.04] digunakan pada VPS.

2. **Bahasa Pemrograman.**

Python [3.11] digunakan sebagai bahasa utama untuk *backend*, pengolahan data, modul *tools*, dan integrasi model bahasa. TypeScript digunakan untuk pengembangan antarmuka pengguna.

3. **Framework dan Library Backend.**

- (a) FastAPI — Membangun layanan *backend* berbasis REST API.
- (b) Uvicorn — *Server ASGI* untuk menjalankan aplikasi FastAPI.
- (c) httpx — Komunikasi HTTP dengan *API* eksternal dan layanan Ollama.
- (d) MySQL Connector — Koneksi antara aplikasi Python dan basis data MySQL.

4. **Framework Frontend.**

- (a) React.js (TypeScript) — Membangun antarmuka pengguna berbasis *component*.
- (b) Vite — *Build tool* untuk mempercepat pengembangan.

- (c) Tailwind CSS — Penataan tampilan antarmuka.

5. Basis Data.

- (a) MySQL — Sistem manajemen basis data relasional utama untuk menyimpan data *real-time* Jawa Timur maupun data historis US EPA.
- (b) XAMPP — Paket distribusi MySQL pada lingkungan pengembangan lokal.

6. Sumber Data Kualitas Udara.

- (a) IQAir API — Sumber data *real-time* untuk 16 kota Jawa Timur (AQI US, polutan dominan, dan parameter cuaca).
- (b) Data Historis US EPA — Konsentrasi mentah empat polutan gas (O₃, NO₂, SO₂, CO) yang digunakan untuk perhitungan AQI mandiri.

7. Large Language Model (LLM) dan Runtime.

- (a) Ollama — *Runtime* untuk menjalankan model LLM secara lokal.
- (b) Llama3.1 8B — Model inti sistem, dipilih karena keseimbangan antara akurasi, dukungan *tool calling*, dan kemampuan berbahasa Indonesia.
- (c) Qwen3 8B — Model pembanding pada pengujian komparatif, dipilih karena mendukung *tool calling* dan memiliki jumlah parameter yang setara dengan model inti.

[Halaman ini sengaja dikosongkan]

BAB IV

PENGUJIAN

Pada bab ini akan dibahas pengujian sistem Oxyra beserta analisis hasilnya. Pengujian dilakukan pada dua subsistem, yaitu subsistem *real-time* Jawa Timur dan subsistem historis US EPA, dengan metode yang disesuaikan terhadap karakteristik data masing-masing: subsistem US EPA diuji melalui validasi akurasi terhadap basis data, sedangkan subsistem Jawa Timur diuji melalui pertanyaan masyarakat awam yang dinilai oleh ahli. Pengujian dilengkapi dengan pengujian strategi anti-halusinasi, perbandingan model tanpa dan dengan arsitektur Oxyra, serta pengujian komparatif dua model LLM pada *pipeline* yang sama.


4.1 Tujuan Pengujian

Pengujian pada penelitian ini dirancang untuk menjawab pertanyaan-pertanyaan berikut:

1. Sejauh mana sistem mampu memberikan informasi kualitas udara yang akurat secara faktual terhadap data acuan pada subsistem US EPA.
2. Sejauh mana strategi anti-halusinasi mampu mencegah sistem menghasilkan informasi yang tidak didukung data.
3. Sejauh mana jawaban sistem dinilai membantu dan mudah dipahami oleh masyarakat awam pada subsistem *real-time* Jawa Timur.
4. Model LLM mana, di antara Llama 3.1 8B dan Qwen3 8B, yang memberikan keseimbangan terbaik antara keandalan, kecepatan, dan kualitas jawaban sebagai komponen inti sistem Oxyra.
5. Sejauh mana jawaban yang dihasilkan melalui arsitektur Oxyra lebih disukai oleh masyarakat awam dibandingkan jawaban model bahasa yang sama tanpa arsitektur Oxyra, diukur melalui pengujian preferensi tersamar.


4.2 Hasil Implementasi Sistem

Sistem Oxyra telah berhasil diimplementasikan dan berjalan secara fungsional sebelum pengujian dilakukan. Sistem menyajikan informasi kualitas udara dalam bentuk percakapan bahasa alami maupun visualisasi grafik. Antarmuka juga menyediakan pemilihan subsistem data (Jawa Timur atau Amerika Serikat) serta pemilihan model LLM (Llama 3.1 atau Qwen3) yang digunakan untuk keperluan pengujian komparatif. Gambar 4.1 menunjukkan tampilan halaman *dashboard* yang menampilkan rata-rata AQI seluruh kota terpantau beserta kategorinya.




Gambar 4.1: Tampilan halaman *dashboard* sistem Oxyra

Gambar 4.2 menunjukkan contoh respons sistem terhadap pertanyaan edukatif mengenai polutan, sedangkan Gambar 4.3 menunjukkan contoh respons terhadap pertanyaan kondisi udara terkini yang memuat nilai AQI, kategori, parameter cuaca, dan saran tindakan.



Gambar 4.2: Contoh Respons Sistem terhadap Pertanyaan Edukatif




Gambar 4.3: Contoh Respons Sistem terhadap Pertanyaan Kondisi Udara Terkini

Setiap jawaban yang memuat data kualitas udara juga dilengkapi dengan catatan bahwa nilai yang disajikan merupakan indikasi skala kota dari satu titik pantau dan tidak menggantikan

data pemantauan lokal resmi. Catatan ini merupakan bagian dari upaya menjaga kejujuran penyampaian informasi.


Selain penyajian dalam bentuk percakapan, sistem menyediakan halaman visualisasi yang memungkinkan pengguna mengamati kondisi kualitas udara secara menyeluruh tanpa harus mengajukan pertanyaan satu per satu. Halaman ini melengkapi antarmuka percakapan, karena sebagian informasi lebih mudah dipahami melalui perbandingan visual daripada melalui uraian kalimat.

Gambar 4.4 menunjukkan visualisasi perbandingan AQI seluruh kota terpantau, yang diurutkan dari nilai tertinggi. Penyajian dalam bentuk diagram batang memungkinkan pengguna langsung mengenali kota dengan kondisi udara terburuk maupun terbaik, sekaligus melihat sebaran kondisi di seluruh wilayah terpantau pada satu tampilan. Nilai yang ditampilkan berasal dari pembacaan terkini yang tersimpan pada basis data, sehingga konsisten dengan nilai yang disampaikan *chatbot* pada percakapan.



Gambar 4.4: Visualisasi Perbandingan AQI Antarkota

Gambar 4.5 menunjukkan visualisasi tren AQI satu kota pada rentang waktu yang dapat dipilih pengguna, yaitu tiga, tujuh, atau tiga puluh hari terakhir. Grafik ini dibangun dari riwayat pengukuran yang dikumpulkan setiap dua jam, sehingga memperlihatkan pola naik-turun kualitas udara sepanjang hari maupun antarhari. Pola berulang yang tampak pada grafik memperkuat temuan analisis pola historis yang diuraikan pada Subbab 4.9, yaitu bahwa kualitas udara suatu kota memiliki kecenderungan yang berulang menurut waktu dalam sehari.



Gambar 4.5: Visualisasi Tren AQI Satu Kota pada Rentang Waktu Terpilih

Kedua visualisasi tersebut dilengkapi catatan yang sama dengan yang disertakan pada jawaban *chatbot*, yaitu bahwa nilai yang disajikan merupakan indikasi pada skala kota dari satu titik pantau dan tidak menggantikan data pemantauan lokal resmi. Konsistensi pencantuman catatan pada seluruh kanal penyajian merupakan bagian dari upaya menjaga kejujuran penyampaian informasi, sehingga pengguna memperoleh pemahaman yang sama mengenai batas keberlakuan data, baik ketika membaca jawaban percakapan maupun ketika mengamati grafik.

4.3 Pengujian Akurasi Subsistem US EPA

4.3.1 Prosedur Pengujian

Pengujian akurasi dilakukan dengan membandingkan jawaban sistem terhadap nilai acuan (*ground truth*) yang dihitung langsung dari basis data US EPA. Disusun 30 pertanyaan validasi yang mencakup empat kategori, yaitu pertanyaan teknis (nilai polutan spesifik, AQI hasil perhitungan, peringkat antarwilayah, dan pola waktu), pertanyaan terapan (rekomendasi lokasi dan waktu aktivitas), pertanyaan edukatif, dan pertanyaan pemancing halusinasi. Berbeda dengan pengujian pada subsistem Jawa Timur yang menggunakan pertanyaan asli responden, seluruh pertanyaan validasi pada subsistem ini disusun sendiri oleh peneliti dengan tujuan memastikan cakupan pengujian menjangkau seluruh polutan dan seluruh jenis kueri yang didukung sistem. Pertanyaan validasi karenanya tidak dimaksudkan mewakili gaya bahasa masyarakat awam, melainkan mewakili cakupan fungsi sistem.

Prosedur validasi dijalankan melalui skrip yang, untuk setiap pertanyaan, mengirimkan pertanyaan ke sistem sekaligus menjalankan kueri SQL pembanding ke basis data sebagai acuan. Sebagai contoh, pertanyaan mengenai negara bagian dengan ozon tertinggi disandingkan dengan kueri agregasi rata-rata AQI ozon per negara bagian yang diurutkan menurun. Jawaban sistem dan hasil kueri ditampilkan berdampingan, kemudian kesesuaian keduanya diperiksa dan dicatat. Kriteria kesesuaian disesuaikan dengan kategori pertanyaan: pertanyaan teknis dan terapan dinilai dari kecocokan nilai dan entitas terhadap hasil kueri acuan; pertanyaan edukatif dinilai dari kebenaran konsep yang disampaikan; sedangkan pertanyaan pemancing halusinasi dinilai dari keberhasilan sistem menolak secara jujur tanpa mengarang nilai.

4.3.2 Hasil dan Analisis

Subsistem US EPA berperan sebagai pengujian akurasi teknis dan kepatuhan terhadap standar, bukan pengujian persepsi. Pilihan ini didasarkan pada karakteristik data: hanya pada subsistem ini tersedia basis data lokal berisi konsentrasi mentah, sehingga nilai yang disampaikan sistem dapat diperiksa ulang melalui kueri, kategorinya dapat diperiksa terhadap *breakpoint* EPA, dan sarannya dapat diperiksa terhadap *cautionary statement* EPA. Ketiga acuan tersebut bersifat deterministik dan terpublikasi, sehingga hasil pengujian dapat diverifikasi ulang oleh pihak lain tanpa bergantung pada penilaian peneliti.

Pelaporan hasil difokuskan pada 18 pertanyaan yang memiliki acuan kueri basis data, yaitu 13 pertanyaan teknis dan 5 pertanyaan terapan. Seluruh 18 pertanyaan tersebut dijawab dengan nilai dan entitas yang cocok terhadap hasil kueri acuan (18 dari 18). Tabel 4.1 menjelaskan tentang sebaran kedua kategori tersebut beserta bentuk acuan yang digunakan. Dua belas pertanyaan lainnya, yang terdiri atas pertanyaan edukatif dan pertanyaan pemancing halusinasi, tidak memiliki acuan kueri sehingga tidak dilaporkan sebagai pengujian akurasi; jawaban atas pertanyaan tersebut tetap dicatat dan disajikan pada lampiran sebagai pengujian pelengkap.

Tabel 4.1: Hasil Validasi Akurasi terhadap Kueri Acuan Basis Data US EPA

Kategori	Bentuk Acuan Kueri	Jumlah	Sesuai
Teknis	Nilai polutan, AQI hasil perhitungan, peringkat antarwilayah, dan pola per jam	13	13
Terapan	Lokasi dan waktu dengan nilai AQI terbaik pada rentang yang diminta	5	5
Total		18	18

Hasil ini konsisten dengan prinsip arsitektur sistem, yaitu bahwa seluruh nilai numerik berasal dari perhitungan kode (rumus interpolasi AQI EPA), bukan dari model bahasa, sehingga kesalahan angka dapat ditekan hingga nol pada pengujian ini. Hasil ini sekaligus menunjukkan bahwa perhitungan AQI mandiri dari konsentrasi mentah telah berjalan sesuai standar EPA, karena nilai yang dihitung sistem cocok dengan nilai yang dihitung langsung dari basis data. Perwakilan pertanyaan beserta jawaban dan kueri acuannya disajikan pada lampiran agar dapat diperiksa secara mandiri.

4.4 Pengujian Strategi Anti-Halusinasi

Bagian ini menguraikan pengujian terhadap strategi anti-halusinasi, yang merupakan salah satu kontribusi utama penelitian. Pengujian dilakukan secara iteratif mengikuti siklus temukan-perbaiki-verifikasi: pengujian awal digunakan untuk menemukan kelemahan, perbaikan dirancang untuk mengatasinya, kemudian pengujian ulang dilakukan untuk memverifikasi.

4.4.1 Temuan Awal

Pada pengujian awal, ditemukan bahwa sistem masih menghasilkan halusinasi pada pertanyaan yang berada di luar lingkup data. Sebagai contoh, pertanyaan mengenai kadar oksigen atau konsentrasi dalam satuan $\mu\text{g}/\text{m}^3$ dijawab dengan angka yang tidak dimiliki sistem, dan pertanyaan mengenai kebijakan tata ruang dijawab dengan saran yang dikarang. Ditemukan pula bahwa penyebutan lokasi yang tidak spesifik (misalnya “daerah saya”) menyebabkan sistem

mengarang nama kota.

4.4.2 Perbaikan yang Diterapkan

Berdasarkan temuan tersebut, diterapkan strategi anti-halusinasi berlapis sebagaimana dijelaskan pada Subbab 3.2.6, yaitu gerbang pertanyaan di luar lingkup, validasi wilayah, penguraian pertanyaan majemuk, dan penanganan kegagalan data. Seluruh nilai numerik juga dipastikan berasal dari kode, bukan dari model bahasa.


4.4.3 Hasil Verifikasi

Setelah perbaikan diterapkan, pengujian ulang menunjukkan bahwa halusinasi angka pada pertanyaan di luar lingkup berhasil ditutup. Pertanyaan mengenai kadar oksigen, persentase polusi, prediksi masa depan, kualitas udara dalam ruangan, dan kebijakan tata ruang ditolak secara sopan tanpa mengarang jawaban. Penyebutan lokasi yang tidak spesifik dijawab dengan permintaan untuk menyebutkan nama kota. Pertanyaan majemuk yang memuat bagian yang dapat dijawab sekaligus bagian di luar lingkup ditangani dengan menjawab bagian yang valid dan menolak bagian yang di luar lingkup dalam satu jawaban yang mengalir.

Pendekatan ini bersifat konservatif: sistem lebih memilih menolak apabila terdapat indikasi pertanyaan di luar lingkup, sehingga sebagian pertanyaan majemuk yang memuat kata kunci tertentu dapat ikut ditolak. Konsekuensi ini merupakan *trade-off* yang disengaja demi menjaga agar sistem tidak menyampaikan informasi yang tidak didukung data, yang untuk konteks informasi kesehatan publik dinilai lebih aman daripada risiko menyesatkan.


Cara kerja strategi anti-halusinasi dapat diperjelas melalui beberapa kasus uji beserta perilaku sistem yang teramati berikut.

Kasus 1 — Pertanyaan Data di Luar Lingkup. Salah satu responden menuliskan “tolong ukur berapa persen kadar oksigen di daerah ini”. Sistem mendeteksi bahwa persentase kadar oksigen bukan bagian dari data yang dimiliki, lalu menolaknya secara sopan tanpa mengarang angka, sebagaimana ditunjukkan pada Gambar 4.6. Penolakan ini terjadi sebelum pertanyaan mencapai model bahasa, sehingga tidak ada peluang bagi model untuk berhalusinasi. Perilaku serupa teramati pada pertanyaan mengenai persentase oksigen, konsentrasi $\mu\text{g}/\text{m}^3$, prediksi masa depan, kualitas udara dalam ruangan, serta kebijakan tata ruang.




Gambar 4.6: Penolakan Pertanyaan di Luar Lingkup (Kadar Oksigen)

Kasus 2 — Lokasi Tidak Spesifik. Seorang responden menuliskan “kok akhir-akhir ini aku sering batuk-batuk ya, ada hubungannya sama kualitas udara di sini?” tanpa menyebut nama kota. Sistem tidak mengarang kota mana pun, melainkan meminta pengguna menyebutkan kota yang dimaksud, sebagaimana Gambar 4.7. Hal ini mencegah sistem memberikan data kota yang keliru akibat menebak lokasi pengguna.



Gambar 4.7: Permintaan Klarifikasi pada Lokasi Tidak Spesifik

Kasus 3 — Pertanyaan Majemuk. Seorang responden mengajukan tiga pertanyaan sekaligus, yaitu kondisi udara Surabaya, kebutuhan masker saat berkendara, dan prediksi kualitas udara keesokan hari untuk bermain golf. Sistem menguraikannya menjadi bagian-bagian terpisah. Bagian yang berada dalam lingkup (kondisi kota dan masker) dijawab, sedangkan bagian yang berupa prediksi masa depan tidak dijawab sebagai kepastian, melainkan diarahkan pada pola historis. Seluruh hasil kemudian dirangkai menjadi satu jawaban yang mengalir, sebagaimana ditunjukkan pada Gambar 4.8.



Gambar 4.8: Penanganan Pertanyaan Majemuk

Ketiga kasus di atas seluruhnya diambil dari pertanyaan asli responden, bukan pertanyaan yang disusun peneliti, sehingga perilaku sistem yang teramati mencerminkan kondisi penggu-

naan nyata. Ketiga kasus tersebut memperlihatkan pola yang konsisten: halusinasi muncul justru ketika model bahasa dibiarkan menjawab di luar batas arsitektur, dan dapat ditekan ketika setiap pertanyaan disaring serta seluruh angka bersumber dari kode. Temuan ini memperkuat prinsip perancangan sistem, yaitu pemisahan peran antara kode sebagai penyedia data dan model bahasa sebagai perangkai kalimat.

4.5 Perbandingan Model Tanpa dan Dengan Arsitektur Oxyra

Kontribusi arsitektur Oxyra dapat ditunjukkan secara lebih tegas melalui perbandingan antara jawaban model bahasa yang sama ketika dijalankan secara mentah (tanpa arsitektur Oxyra) dan ketika dijalankan di dalam sistem Oxyra. Perbandingan menggunakan model dasar yang identik (Llama 3.1 8B) dan pertanyaan yang identik, yaitu pertanyaan mengenai kaitan batuk dengan kualitas udara pada musim kemarau.

Ketika dijalankan secara mentah, model menghasilkan jawaban yang sangat panjang dan memuat banyak klaim yang tidak didukung data terukur, seperti klaim kualitatif bahwa kualitas udara “kurang baik” tanpa mengakses data apa pun (padahal kondisi aktual saat pengujian berada pada kategori Sedang), spekulasi diagnosis seperti infeksi dan bronkitis, hingga saran yang melebar jauh dari domain seperti mencuci tangan, mengelola stres, dan berkonsultasi dengan dokter. Jawaban semacam ini, meskipun terdengar meyakinkan, sebagian besar merupakan pengetahuan umum model yang tidak berasal dari data kualitas udara aktual, sehingga rentan menyesatkan apabila disajikan sebagai informasi resmi.

Jawaban yang dihasilkan melalui sistem Oxyra untuk pertanyaan yang sama justru jauh lebih ringkas dan berpijak pada data yang dimiliki sistem, yaitu kondisi terkini suhu, kelembaban, kategori kualitas udara, dan polutan dominan hasil pemanggilan fungsi, dengan penjelasan kaitan kesehatan yang bersifat kualitatif dan terbatas.

Gambar 4.9 menunjukkan cuplikan jawaban model mentah melalui antarmuka Ollama, sedangkan Gambar 4.10 menunjukkan jawaban sistem Oxyra terhadap pertanyaan yang sama persis. Jawaban model mentah terlalu panjang untuk ditampilkan seluruhnya dalam satu tangkapan layar; transkrip lengkapnya disajikan pada lampiran.

```
PS C:\Users\Chowder> ollama run llama3.1:8b
>>> Kok akhir-akhir ini aku sering batuk-batuk ya, apa hubungannya sama kualitas udara di surabaya??
Batuk bisa disebabkan oleh beberapa hal seperti peradangan pada saluran napas atau infeksi. Kualitas udara yang kurang baik juga dapat mempengaruhi sistem pernapasan kita, terutama jika ada polusi udara berlebihan di sekitar kita.
```

Berikut beberapa hal terkait kualitas udara Surabaya yang mungkin dapat mempengaruhi batuk Anda:


1. ****Polusi Udara****: Surabaya sering mendapat julukan "Kota Pahlawan" tetapi juga dikenal sebagai salah satu kota di Indonesia dengan polusi udaranya paling parah. Polusi udara yang berlebihan dapat menyebabkan peradangan pada sistem pernapasan dan meningkatkan risiko batuk.
2. ****Kondisi Cuaca****: Surabaya memiliki iklim tropis dengan curah hujan yang tidak terlalu tinggi, tetapi cuaca yang panas dan lembap dapat memperburuk polusi udara. Kelembaban tinggi dapat membuat partikel-partikel polutan lebih mudah menempel pada saluran pernapasan.
3. ****Aktivitas Industri****: Surabaya juga dikenal sebagai kota industri karena banyaknya pabrik dan kegiatan industri lainnya. Gas-gas berbahaya seperti NOx, SO2, dan CO dapat dihasilkan dari proses industri ini dan meningkatkan polusi udara.

Untuk mengurangi risiko batuk akibat kualitas udara Surabaya, Anda bisa melakukan beberapa hal:

1. ****Menggunakan Masker****: Mengenakan masker saat berada di luar rumah atau di tempat yang sering terkena polusi dapat membantu melindungi sistem pernapasan.
2. ****Hindari Aktivitas Luar Ruangan Pada Waktu Polusi Udara Tinggi****: Banyak aplikasi ponsel yang memberikan informasi mengenai kualitas udara di Surabaya. Hindari melakukan kegiatan luar ruangan pada waktu polusi udaranya tinggi.
3. ****Mengonsumsi Makanan Seimbang****: Menjaga kebersihan dan menjaga nutrisi tubuh yang baik dapat membantu sistem pernapasan lebih kuat dalam menghadapi kualitas udara yang kurang baik.

Jika batuk Anda tidak membaik setelah melakukan langkah-langkah di atas, sebaiknya berkonsultasilah dengan dokter untuk mengetahui penyebab pasti dan mendapatkan saran terbaik.

Gambar 4.9: Cuplikan Jawaban Model Mentah (Llama 3.1 melalui Ollama) tanpa Arsitektur Oxyra



Gambar 4.10: Jawaban Sistem Oxyra terhadap Pertanyaan yang Sama

Tabel 4.2 menjelaskan tentang perbandingan kedua jawaban tersebut dalam tiga dimensi utama.

Tabel 4.2: Perbandingan Jawaban Model Mentah dan Sistem Oxyra (Model Dasar Sama)

Dimensi	Model Mentah	Sistem Oxyra
Sumber informasi	Pengetahuan parametrik model, tanpa akses data	Data <i>real-time</i> melalui pemanggilan fungsi
Klaim kondisi udara	Kualitatif tanpa dasar (“kurang baik”), bertentangan dengan kondisi aktual	Nilai AQI, suhu, dan kelembaban aktual sesuai data
Cakupan saran	Melebar ke ranah medis dan gaya hidup di luar domain	Terbatas pada domain kualitas udara

Perbandingan ini menegaskan bahwa arsitektur Oxyra berfungsi sebagai pengendali yang menjaga model tetap berada dalam batas data yang dapat dipertanggungjawabkan, alih-alih membiarkannya menghasilkan informasi yang tidak terkontrol. Karena model dasarnya sama, seluruh perbedaan perilaku pada perbandingan ini merupakan kontribusi arsitektur, bukan kontribusi model.

Perlu ditegaskan bahwa sistem tetap membedakan dua jenis muatan jawaban. Data terukur, seperti nilai AQI, suhu, dan kelembaban, sepenuhnya berasal dari perhitungan kode dan bersifat pasti. Sementara itu, penjelasan kualitatif mengenai kaitan parameter tersebut dengan kenyamanan pernapasan merupakan pengayaan yang berbasis pengetahuan umum model, yang sengaja dibatasi dan tidak disajikan sebagai data terukur maupun diagnosis medis. Pemisahan yang disengaja ini menjaga keseimbangan antara kekayaan informasi dan keandalannya. Pada pengujian juga teramati bahwa pembukaan jawaban yang menolak aspek medis kadang tetap diikuti saran kehati-hatian yang menyinggung kondisi sensitif; inkonsistensi ringan antara pernyataan pembatas dan isi jawaban ini didokumentasikan sebagai keterbatasan model 8B dalam merangkai bahasa (Subbab 4.10.2).

4.6 Pengujian Kepuasan Responden terhadap Jawaban Sistem

Perbandingan pada Subbab 4.5 menunjukkan kontribusi arsitektur Oxyra melalui analisis isi jawaban. Pengujian pada bagian ini melengkapinya dari sisi persepsi pengguna, yaitu menguji apakah jawaban yang dihasilkan melalui arsitektur Oxyra memang lebih disukai oleh masyarakat awam dibandingkan jawaban model mentah, tanpa responden mengetahui asal masing-masing jawaban.

Pengujian dilakukan sesuai desain pada Subbab 3.2.10. Sebanyak 10 responden menilai empat pasangan jawaban tersamar atas pertanyaan yang identik, dengan kedua jawaban pada tiap pasangan dihasilkan oleh model dasar yang sama. Gambar 4.11 menunjukkan contoh satu pasangan jawaban sebagaimana disajikan kepada responden, tanpa keterangan sistem yang menghasilkan masing-masing jawaban. Tabel 4.3 menjelaskan tentang hasil pemilihan responden pada tiap pasangan pertanyaan.

Hasil pada Tabel 4.3 menunjukkan bahwa mayoritas responden memilih jawaban yang dihasilkan sistem Oxyra pada keempat pasangan pertanyaan. Karena responden tidak mengetahui asal tiap jawaban dan model dasar keduanya identik, preferensi tersebut dapat dikaitkan pada karakteristik jawaban yang dibentuk oleh arsitektur, yaitu jawaban yang lebih ringkas, berpijak pada data aktual, dan disertai saran tindakan yang terarah, dibandingkan jawaban model mentah yang panjang dan memuat klaim tanpa dukungan data.

Pertanyaan 1

Seorang responden bertanya: "Bagaimana kualitas udara di daerah surabaya pada hari ini?"

Berikut dua jawaban dari dua sistem berbeda. Bacalah keduanya, lalu jawab pertanyaan di bawah.

Jawaban A

Kualitas udara di Surabaya hari ini cukup baik dengan AQI 70, kategori Sedang. Suhu sekitar 27°C dan kelembaban 79%. Karena polutan dominan PM2.5, sebaiknya Anda mempertimbangkan mengurangi aktivitas luar yang berat jika sangat sensitif terhadap udara. Boleh melakukan aktivitas sehari-hari dengan menggunakan masker. Catatan: angka/kondisi di atas adalah indikasi skala kota (satu titik pantau per kota) dan tidak menggantikan data pemantauan lokal resmi seperti stasiun DLH/KLH atau sensor di sekitar lokasi Anda.

Jawaban B

Maaf, saya tidak dapat memantau cuaca dan kondisi lingkungan sekitar secara real-time. Untuk mengetahui kualitas udara di Surabaya pada hari ini, silakan periksa situs web resmi Badan Lingkungan Hidrologi (BBSDH) atau aplikasi AirVisual yang menyediakan informasi cuaca dan kualitas udara secara real-time.

Jawaban mana yang lebih mudah dipahami? *

☐ Jawaban A

☐ Jawaban B

☐ Sama saja

Gambar 4.11: Contoh Pasangan Jawaban Tersamar pada Kuesioner Kepuasan

Tabel 4.3: Hasil Pengujian Kepuasan Responden (10 Responden)

Pasangan	Aspek Penilaian	Oxyra	Model Mentah	Sama Saja
1	Mudah dipahami	9	1	0
	Membantu keputusan	10	0	0
	Preferensi keseluruhan	9	0	1
2	Mudah dipahami	9	0	1
	Membantu keputusan	9	1	0
	Preferensi keseluruhan	9	0	1
3	Mudah dipahami	9	0	1
	Membantu keputusan	10	0	0
	Preferensi keseluruhan	9	0	1
4	Mudah dipahami	9	0	1
	Membantu keputusan	9	0	1
	Preferensi keseluruhan	10	0	0
Total (120 penilaian)		111	2	7

Jumlah responden pada pengujian ini terbatas (10 orang), sehingga hasilnya diposisikan sebagai indikasi pendukung yang konsisten dengan temuan penilaian ahli, bukan sebagai generalisasi statistik. Keterbatasan ini diuraikan lebih lanjut pada Subbab 4.9.2.


4.7 Pengujian Persepsi Awam Subsistem Jawa Timur

4.7.1 Prosedur Pengujian

Pengujian pada subsistem *real-time* Jawa Timur difokuskan pada sejauh mana jawaban sistem membantu masyarakat awam, bukan semata-mata pada ketepatan angka. Prosedur pengujian mengikuti desain instrumen yang telah diuraikan pada Subbab 3.2.10: pertanyaan dikumpulkan dari 40 responden melalui kuesioner daring, dikirimkan ke sistem dengan mempertahankan gaya bahasa asli responden, kemudian jawaban sistem dinilai oleh ahli menggunakan skala 5 hingga 10. Penilaian dilakukan oleh validator ahli bidang lingkungan, bersamaan dengan pengujian komparatif dua model yang diuraikan pada Subbab 4.8. Validator ahli tersebut merupakan penilai independen yang bukan penulis pada penelitian ini serta tidak terlibat dalam perancangan maupun implementasi sistem, sehingga penilaian yang diberikan bebas dari kepentingan pengembang.

4.7.2 Karakteristik Responden

Kuesioner diisi oleh 40 responden dengan rentang usia yang beragam. Sebagian besar responden berada pada rentang usia 20–35 tahun (52,5%), diikuti oleh responden berusia di bawah 20 tahun (27,5%), usia 36–50 tahun (7,5%), dan di atas 50 tahun (12,5%). Komposisi ini ditunjukkan pada Gambar 4.12. Keberagaman usia ini penting agar pertanyaan yang terkumpul mewakili beragam cara masyarakat awam menanyakan kondisi kualitas udara.



Gambar 4.12: Distribusi Usia Responden Kuesioner

4.7.3 Karakteristik Pertanyaan Awam

Pertanyaan yang diperoleh dari 40 responden, setelah dikelompokkan berdasarkan kesamaan maksud, menunjukkan pola yang konsisten. Sebagian besar pertanyaan awam berorientasi pada implikasi tindakan, seperti keamanan beraktivitas di luar, kebutuhan penggunaan masker, dan waktu terbaik untuk beraktivitas, alih-alih menanyakan nilai teknis seperti angka AQI. Temuan ini memperkuat asumsi bahwa masyarakat awam lebih membutuhkan interpretasi dan rekomendasi tindakan daripada data numerik mentah.

Dari 40 pertanyaan yang terkumpul, dipilih 12 pertanyaan yang mewakili seluruh ragam maksud sekaligus seluruh jalur pemrosesan sistem untuk dinilai oleh ahli. Tabel 4.4 menjelaskan tentang kedua belas pertanyaan tersebut beserta maksud yang diuji pada masing-masing pertanyaan. Pemilihan ini disengaja agar penilaian tidak hanya menyentuh pertanyaan yang mudah dijawab, melainkan juga pertanyaan yang menantang batas sistem, seperti pertanyaan dengan lokasi tidak spesifik, pertanyaan di luar lingkup data, serta pertanyaan majemuk yang memuat beberapa maksud sekaligus.

Tabel 4.4: Pertanyaan Responden yang Diujikan dan Dinilai Ahli

No	Pertanyaan Responden (Gaya Asli)	Maksud yang Diuji
1	Seberapa bagus kualitas udara di sana?	Lokasi tidak spesifik
2	Kok akhir-akhir ini aku sering batuk-batuk ya, ada hubungannya sama kualitas udara di sini?	Batas medis; lokasi tidak spesifik
3	Cuaca, kesehatan, mungkin bisa rekomendasikan masker apa yang bisa cukup untuk menyaring udara tergantung dengan tingkat bahayanya, angin, hujan	Rekomendasi produk (di luar lingkup)
4	Apakah polusi akan memburuk secara kualitas di 2030?	Prediksi jangka panjang
5	Berapa tingkat polusi hari ini?	Kondisi terkini tanpa lokasi
6	Seberapa bersih kadar udara di Surabaya?	Kondisi terkini, lokasi spesifik
7	Hari ini udaranya lagi bersih gak ya buat jalan-jalan sore atau sekadar duduk di luar? Kira-kira jam berapa yang paling aman dari polusi kalau mau keluar rumah?	Majemuk: kondisi dan pola waktu
8	Tolong ukur berapa persen kadar polusi di daerah ini	Satuan di luar lingkup; lokasi tidak spesifik
9	Bagaimana kualitas udara hari ini di Surabaya? Apakah saya perlu pakai masker kalau saya keluar motoran di hari ini? Besok saya mau golf, gimana prediksi kualitas udara besok?	Majemuk: kondisi, saran pelindung, dan prediksi
10	Alergen apa saja yang terkandung di udara? Polutan apa yang saat ini beredar di udara? Apakah udara di sekitar mengandung virus menular?	Data biologis (di luar lingkup)
11	Kenapa kita bisa sakit dari udara yang kotor?	Edukatif
12	Gimana kualitas udara di daerahku hari ini? Aman gak kalau aku olahraga di luar sekarang?	Majemuk; lokasi tidak spesifik

Sebaran pada tabel tersebut menunjukkan bahwa penilaian tidak dilakukan pada kondisi yang menguntungkan sistem. Hanya sebagian kecil pertanyaan yang dapat dijawab melalui jalur normal, yaitu pertanyaan kondisi terkini dengan lokasi yang jelas. Selebihnya justru menguji lapisan anti-halusinasi: empat pertanyaan menyangkut data yang tidak dimiliki sistem, empat pertanyaan menyebut lokasi secara tidak spesifik, dan tiga pertanyaan memuat beberapa maksud sekaligus. Skor yang diperoleh karenanya mencerminkan kemampuan sistem menghadapi pertanyaan yang menantang, bukan sekadar pertanyaan yang mudah.

Sejumlah pertanyaan juga teridentifikasi berada di luar lingkup sistem, seperti pertanyaan medis, prediksi masa depan, kualitas udara dalam ruangan, serta kebijakan lingkungan. Pertanyaan-pertanyaan ini menjadi bahan penting dalam pembahasan keterbatasan sistem, sekaligus menunjukkan bahwa harapan masyarakat awam terhadap sistem informasi kualitas udara sering kali melampaui cakupan data yang tersedia.

4.7.4 Hasil Penilaian Ahli

Seluruh 40 pertanyaan responden diujikan ke sistem tanpa penyaringan, termasuk pertanyaan yang berada di luar lingkup maupun di luar topik, agar perilaku sistem tercatat pada kondisi penggunaan nyata. Dari keseluruhan jawaban tersebut, 12 pertanyaan yang mewakili ragam maksud utama—kondisi terkini, saran aktivitas, kebutuhan pelindung, pola waktu, serta pertanyaan di luar lingkup—dinilai oleh ahli. Jawaban sistem dengan model inti Llama 3.1 8B memperoleh skor rata-rata 8,58 dari skala 5–10. Skor ini menunjukkan bahwa jawaban sistem secara umum dinilai membantu dan layak bagi masyarakat awam, termasuk pada pertanyaan yang dijawab dengan penolakan sopan karena berada di luar lingkup; penolakan yang jujur dinilai tetap merupakan jawaban yang baik, bukan kegagalan sistem. Jawaban atas pertanyaan yang tidak termasuk dalam penilaian ahli tetap dicatat dan disajikan pada lampiran sebagai data pendukung.

Pengujian ini sekaligus memperlihatkan letak kecerdasan sistem yang dikembangkan. Berbeda dengan sistem informasi konvensional yang datanya cukup diambil melalui kueri yang disusun manusia, kecerdasan sistem pada pengujian ini tampak pada dua hal. Pertama, kemampuan menginterpretasikan pertanyaan bahasa alami menjadi aksi pengambilan data: seluruh pertanyaan diajukan dengan gaya bahasa asli masyarakat awam tanpa penyesuaian, termasuk ejaan tidak baku, lokasi yang tidak disebutkan, dan beberapa maksud dalam satu kalimat. Sistem memahami konteks pertanyaan tersebut lalu menerjemahkannya menjadi pemanggilan fungsi dan kueri yang sesuai, tanpa responden perlu mengetahui struktur data di balik sistem. Kedua, kemampuan membahasakan informasi dalam konteks masyarakat awam: jawaban yang dinilai ahli tidak berhenti pada angka kuantitatif, melainkan berupa uraian deskriptif yang memuat interpretasi kondisi dan saran tindakan. Skor rata-rata 8,58 dari validator ahli merupakan validasi bahwa kedua kemampuan tersebut berjalan pada pertanyaan pengguna yang sesungguhnya, bukan pada pertanyaan yang disusun peneliti.

Tabel 4.5 menjelaskan tentang rincian skor yang diberikan ahli untuk kedua model pada kedua belas pertanyaan tersebut.

Tabel 4.5: Skor Penilaian Ahli per Pertanyaan (Skala 5–10)

No	Pertanyaan Responden	Llama 3.1	Qwen3
1	Seberapa bagus kualitas udara di sana?	9	7
2	Kok akhir-akhir ini aku sering batuk-batuk ya, ada hubungannya sama kualitas udara di sini?	8	6
3	Cuaca, kesehatan, mungkin bisa rekomendasi masker apa yang bisa cukup untuk menyaring udara	7	8
4	Apakah polusi akan memburuk secara kualitas di 2030?	8	8
5	Berapa tingkat polusi hari ini?	8	9
6	Seberapa bersih kadar udara di Surabaya?	9	9
7	Hari ini udaranya lagi bersih gak ya buat jalan-jalan sore? Jam berapa yang paling aman?	7	9
8	Tolong ukur berapa persen kadar polusi di daerah ini	9	9
9	Kualitas udara Surabaya? Perlu masker? Prediksi besok untuk golf?	10	10
10	Alergen apa saja di udara? Apakah udara mengandung virus menular?	10	8
11	Kenapa kita bisa sakit dari udara yang kotor?	9	8
12	Kualitas udara di daerahku? Aman gak olahraga di luar sekarang?	9	8
Rata-rata		8,58	8,25

Sebaran skor pada tabel tersebut menunjukkan bahwa kedua model memperoleh nilai tertinggi pada pertanyaan majemuk (nomor 9) yang dijawab dengan menguraikan setiap bagian pertanyaan dan mengarahkan bagian prediksi pada pola historis. Skor terendah pada Qwen3 justru muncul pada pertanyaan yang tidak memicu pemanggilan *tool* (nomor 1 dan 2), yaitu ketika model menyusun jawaban dari pengetahuannya sendiri dan mengarang nilai AQI beberapa kota. Pola ini konsisten dengan temuan audit halusinasi yang diuraikan pada Subbab 4.8.

Penilaian ahli hanya dilakukan pada subsistem *real-time* Jawa Timur. Hal ini merupakan pilihan yang disengaja: penilaian kebermanfaatan bagi masyarakat awam Indonesia hanya bermakna pada wilayah yang relevan bagi responden. Subsistem US EPA karenanya tidak diuji dari sisi persepsi, melainkan dari sisi akurasi terhadap basis data (Subbab 4.3) serta pengukuran objektif berupa halusinasi dan waktu respons.

4.8 Pengujian Komparatif Dua Model LLM

4.8.1 Rancangan Pengujian

Pengujian komparatif dilakukan untuk menilai kesesuaian model inti dengan membandingkan dua model LLM lokal berukuran setara, yaitu Llama 3.1 8B sebagai model inti dan Qwen3 8B sebagai model pembanding, pada *pipeline* Oxyra yang identik. Seluruh komponen

backend, *tools*, gerbang anti-halusinasi, dan data ditetapkan sama; hanya model LLM yang dipertukarkan, sehingga perbedaan respons mencerminkan kapabilitas tiap model dalam memanfaatkan konteks yang identik.

Pemilihan model pembandingan melalui proses seleksi tersendiri. Model SahabatAI 8B, yang unggul dalam nuansa Bahasa Indonesia, semula dipertimbangkan sebagai pembandingan; model tersebut tidak dapat digunakan karena tidak mendukung mekanisme pemanggilan fungsi (*tool calling*) yang menjadi landasan arsitektur sistem. Temuan ini sekaligus menegaskan bahwa dukungan *tool calling* merupakan prasyarat teknis yang membatasi pilihan model pada arsitektur semacam ini. Qwen3 8B dipilih karena mendukung *tool calling* dan memiliki jumlah parameter yang setara dengan model inti, sehingga perbandingan keduanya adil dari sisi ukuran model.

Instrumen pengujian dirancang seragam pada kedua subsistem. Pada subsistem Jawa Timur, digunakan 40 pertanyaan asli responden tanpa perubahan sedikit pun, termasuk pertanyaan dengan ejaan tidak baku maupun pertanyaan di luar topik. Pada subsistem US EPA, digunakan 40 pertanyaan yang sama dengan kata-kata responden dipertahankan dan hanya entitas lokasi yang disesuaikan (misalnya Surabaya menjadi California), sehingga variabel gaya bahasa terkontrol dan yang divariasikan hanya konteks data. Rancangan ini menguji konsistensi pendekatan terhadap dua karakteristik data yang berbeda, sesuai kerangka yang diuraikan pada Bab 3.

Perbandingan kedua model dilakukan pada tiga aspek dengan basis data yang berbeda sesuai sifat pengukurannya. Skor penilaian ahli bersumber dari 12 pertanyaan subsistem Jawa Timur yang dinilai oleh ahli. Halusinasi dan waktu respons diukur secara objektif dari catatan seluruh 80 jawaban (40 per subsistem), tanpa memerlukan penilaian ahli, sehingga dapat ditelusuri ulang dari berkas hasil pengujian.

Dua penyesuaian interpretasi perlu dicatat secara jujur pada rancangan ini. Pertama, makna temporal bergeser antar-subsistem: frasa seperti “hari ini” pada subsistem Jawa Timur merujuk pada kondisi *real-time*, sedangkan pada subsistem US EPA dimaknai sebagai data terbaru yang tersedia dalam basis data historis. Kedua, cakupan data kedua subsistem tidak identik: subsistem Jawa Timur memiliki parameter cuaca sehingga pertanyaan mengenai suhu dapat dijawab, sedangkan subsistem US EPA tidak memiliki data cuaca sehingga pertanyaan serupa ditolak oleh gerbang di luar lingkup. Perbedaan perilaku pada pertanyaan-pertanyaan tersebut bersumber dari cakupan data, bukan dari kegagalan arsitektur; penolakan yang konsisten justru menunjukkan gerbang bekerja sebagaimana dirancang. Sebagai catatan teknis instrumen, jawaban pada berkas penilaian disimpan dalam format satu baris (karakter baris baru diratakan) untuk keperluan penskoran; format asli jawaban, sebagaimana ditampilkan antarmuka web, mempertahankan struktur paragraf.

4.8.2 Hasil dan Analisis

Tabel 4.6 menjelaskan tentang rekapitulasi hasil pengujian komparatif kedua model, mencakup skor penilaian ahli (12 pertanyaan Jawa Timur), jumlah jawaban berhalusinasi, dan rata-rata waktu respons (keduanya diukur dari 80 jawaban yang dihasilkan tiap model).

Tabel 4.6: Rekapitulasi Pengujian Komparatif Llama 3.1 8B dan Qwen3 8B

Aspek	Llama 3.1 8B	Qwen3 8B
Skor penilaian ahli, skala 5–10 (12 pertanyaan)	8,58	8,25
Jawaban mengklaim kondisi tanpa dukungan data (dari 80 per model)	0	6
Rata-rata waktu respons Jawa Timur (s)	15,4	31,4
Rata-rata waktu respons US EPA (s)	24,4	36,5

Halusinasi pada tabel di atas didefinisikan secara operasional sehingga dapat diaudit ulang: sebuah jawaban dinyatakan berhalusinasi apabila mengklaim kondisi aktual—berupa nilai AQI, suhu, kelembaban, polutan dominan, maupun lokasi—yang tidak terdapat pada data hasil pemanggilan fungsi yang tercatat untuk pertanyaan tersebut. Penyebutan angka dalam penjelasan skala AQI, misalnya pernyataan bahwa nilai di atas 100 tergolong tidak sehat, tidak dihitung sebagai halusinasi karena merupakan pengetahuan standar EPA yang benar dan bukan klaim kondisi aktual.

Setiap model menjawab 80 pertanyaan yang sama (40 per subsistem), sehingga menghasilkan 80 jawaban per model. Audit terhadap jawaban tersebut menemukan enam jawaban Qwen3 yang mengklaim kondisi tanpa dukungan data, seluruhnya pada subsistem Jawa Timur, sedangkan seluruh jawaban Llama 3.1 lolos audit tanpa satu pun nilai yang dikarang.

Pola kegagalannya konsisten dan penting: keenam halusinasi Qwen3 terjadi pada jawaban yang catatan pemanggilan fungsinya kosong, yaitu ketika model memilih tidak memanggil *tool* sama sekali lalu menyusun jawaban dari pengetahuannya sendiri. Tiga di antaranya menyajikan daftar nilai AQI beberapa kota yang seluruhnya tidak berasal dari data sistem, dan salah satunya bahkan menyebut kota yang sama sekali tidak dipantau sistem; dua mengarang nilai AQI sekaligus suhu dan kelembaban; dan satu menyebutkan nilai suhu yang tidak terdapat pada data.

Tidak ditemukan halusinasi pada subsistem US EPA untuk kedua model. Pada subsistem tersebut, pertanyaan yang tidak menyebut polutan maupun wilayah yang cukup spesifik dicegat oleh gerbang klarifikasi, sehingga model tidak memperoleh kesempatan untuk berimprovisasi. Struktur data yang menuntut kespesifikan dengan demikian berperan sebagai lapisan pengamanan tambahan.


Temuan ini menegaskan batas kerja arsitektur anti-halusinasi: gerbang penyaringan dan pemisahan angka bekerja sebagaimana dirancang, namun jaminan tersebut hanya berlaku sepanjang model mematuhi mekanisme pemanggilan fungsi. Kepatuhan terhadap *tool calling* dengan demikian bukan sekadar syarat teknis, melainkan penentu keandalan sistem—dan pada aspek inilah kedua model berbeda secara tegas. Perbedaan ini menjadi pembeda paling menentukan: pada sistem informasi kesehatan publik, satu nilai yang dikarang lebih merugikan daripada selisih gaya bahasa.

Dari sisi skor penilaian ahli, kedua model memperoleh nilai yang relatif berdekatan (8,58 berbanding 8,25), yang menunjukkan bahwa kualitas bahasa dan kebermanfaatan jawaban keduanya sama-sama layak. Penilaian ahli turut mencatat perbedaan gaya: jawaban Llama 3.1 dinilai lebih luwes dan ramah bagi pengguna awam, sedangkan Qwen3 cenderung lebih berstruktur dan berfokus pada penyajian data. Karakteristik gaya ini tetap teramati pada format asli jawaban di antarmuka web; kesan kaku pada berkas penilaian sebagian diperkuat oleh format satu-baris yang paling memengaruhi jawaban berstruktur daftar, namun karena kedua model dinilai pada

format yang sama, arah perbandingan gaya tersebut tetap sah. Dari sisi kecepatan, Llama 3.1 konsisten sekitar dua kali lebih cepat pada subsistem Jawa Timur dan sekitar satu setengah kali lebih cepat pada subsistem US EPA; sebagian selisih ini berasal dari mode penalaran internal Qwen3 yang menghasilkan proses berpikir sebelum jawaban akhir. Kecepatan respons berpengaruh langsung pada kenyamanan penggunaan sistem percakapan.

Kombinasi ketiga aspek tersebut—keandalan tanpa halusinasi, waktu respons yang lebih cepat, dan skor penilaian yang sedikit lebih tinggi—mengonfirmasi Llama 3.1 8B sebagai model inti sistem Oxyra. Konsistensi hasil antar-subsistem juga memberikan indikasi penting: meskipun subsistem Jawa Timur dan US EPA memiliki karakteristik data yang sangat berbeda, keduanya dapat dilayani oleh arsitektur yang sama tanpa perubahan mendasar pada mekanisme inti. Hal ini menunjukkan bahwa pendekatan yang dikembangkan tidak terikat pada satu sumber data tertentu, melainkan dapat diterapkan pada berbagai konteks data kualitas udara selama tersedia mekanisme pengambilan data yang sesuai.

Gambar 4.13 menunjukkan respons subsistem US EPA atas pertanyaan mengenai kualitas udara Los Angeles pada tanggal tertentu, sedangkan Gambar 4.14 menunjukkan hasil kueri acuan pada basis data untuk pertanyaan yang sama. Pasangan gambar tersebut sekaligus memverifikasi tiga hal: model bahasa berhasil mengekstrak parameter waktu dari pertanyaan berbahasa alami dan meneruskannya ke pemanggilan fungsi; seluruh nilai konsentrasi yang disampaikan sistem terdapat pada baris data yang bersesuaian; serta nilai AQI hasil perhitungan mandiri sistem konsisten dengan *breakpoint* EPA, yaitu konsentrasi ozon 0,066 ppm yang menghasilkan AQI 87 pada kategori Sedang sementara stasiun lain berada pada kategori Baik. Penggunaan tanggal spesifik juga membuat bukti ini dapat diverifikasi ulang kapan pun, karena kueri acuan menghasilkan baris data yang sama.




Gambar 4.13: Respons Subsistem US EPA atas Pertanyaan Bertanggal Spesifik

	123 site	AZ nama_lokasi	waktu	123 nilai	123 aqi	AZ kategori
1	9,035	Lancaster	2025-07-12 23:00:00	0.066	87	Sedang
2	6,012	Newhall, Santa Clarita	2025-07-12 23:00:00	0.038	35	Baik
3	4,010	North Hollywood, Los Angeles	2025-07-12 23:00:00	0.03	28	Baik
4	4,009	Signal Hill	2025-07-12 23:00:00	0.035	32	Baik
5	2,005	Pasadena	2025-07-12 23:00:00	0.027	25	Baik
6	1,701	Pomona	2025-07-12 23:00:00	0.024	22	Baik
7	1,302	Compton	2025-07-12 23:00:00	0.035	32	Baik
8	1,201	Reseda, Los Angeles	2025-07-12 23:00:00	0.029	27	Baik
9	1,103	Central LA, Los Angeles	2025-07-12 23:00:00	0.033	31	Baik
10	113	Los Angeles	2025-07-12 23:00:00	0.036	33	Baik

Gambar 4.14: Hasil Kueri Acuan pada Basis Data untuk Pertanyaan yang Sama

Perbedaan gaya antar model dapat diamati langsung pada pertanyaan yang sama. Gambar 4.15 menunjukkan respons Qwen3 terhadap pertanyaan edukatif yang identik dengan pertanyaan pada Gambar 4.2 yang dijawab oleh model inti Llama 3.1. Kedua model sama-sama menjawab dengan benar; Llama 3.1 menyampaikannya dengan bahasa yang lebih sederhana bagi pengguna awam, sedangkan Qwen3 menyajikan penjelasan yang lebih teknis dan berstruktur.



Gambar 4.15: Contoh Respons Model Pembandingan Qwen3 pada Pertanyaan yang Sama

Gerbang klarifikasi juga bekerja pada subsistem US EPA. Pertanyaan yang menyebut wilayah terlalu luas, misalnya kondisi kualitas udara satu negara bagian secara keseluruhan tanpa menyebut polutan maupun wilayah yang lebih spesifik, tidak dijawab dengan nilai agregat yang dikarang, melainkan direspons dengan permintaan agar pengguna menyebutkan wilayah atau polutan yang dimaksud. Perilaku ini setara dengan penanganan lokasi tidak spesifik pada subsistem Jawa Timur, sehingga menunjukkan bahwa strategi anti-halusinasi bekerja konsisten pada kedua subsistem meskipun struktur datanya berbeda.


4.9 Analisis Pola Historis

Sistem juga diuji dalam menjawab pertanyaan mengenai pola kualitas udara berdasarkan riwayat data yang terkumpul. Pertanyaan mengenai waktu terbaik beraktivitas maupun kecenderungan kondisi dijawab berdasarkan pola historis dengan tetap menegaskan bahwa keluaran merupakan gambaran berdasarkan pola beberapa hari terakhir dan bukan prediksi. Pada kota dengan variasi antarwaktu yang cukup besar, sistem dapat menunjukkan periode yang biasanya lebih baik; sedangkan pada kota dengan variasi kecil, sistem menyatakan bahwa kondisi relatif stabil sepanjang hari. Pendekatan ini menjaga agar sistem tidak memberikan kesan meramalkan masa depan secara pasti.


Gambar 4.16 menunjukkan contoh visualisasi tren AQI yang menyertai jawaban sistem ketika pengguna menanyakan riwayat suatu kota. Gambar 4.17 menunjukkan contoh jawaban atas pertanyaan berorientasi aktivitas (waktu yang baik untuk berolahraga), yang dijawab berdasarkan pola periode waktu tanpa memberikan kepastian prediksi. Gambar 4.18 menunjukkan contoh jawaban atas pertanyaan pola per jam beserta pembingkatannya sebagai gambaran historis.



Gambar 4.16: Contoh Visualisasi Tren AQI pada Jawaban Sistem



Gambar 4.17: Contoh Jawaban Pertanyaan Berorientasi Aktivitas Berbasis Pola Historis



Gambar 4.18: Contoh Jawaban Pola Waktu Harian dengan Pembungkahan Non-Prediktif

4.10 Analisis dan Keterbatasan

Pada bagian ini akan dibahas analisis menyeluruh terhadap hasil seluruh pengujian yang telah diuraikan pada bagian-bagian sebelumnya, mencakup validasi akurasi subsistem US EPA, pengujian strategi anti-halusinasi, pengujian persepsi awam subsistem Jawa Timur, serta pengujian komparatif dua model LLM. Analisis dilakukan untuk merangkai temuan-temuan tersebut menjadi kesimpulan mengenai efektivitas pendekatan yang dikembangkan, sekaligus menjawab letak kecerdasan sistem yang menjadi tolok ukur penelitian. Selanjutnya, diuraikan pula keterbatasan-keterbatasan sistem yang teridentifikasi selama pengujian.

4.10.1 Analisis Keseluruhan

Secara keseluruhan, hasil pengujian menunjukkan bahwa pendekatan pemisahan peran—kode untuk data dan perhitungan, model bahasa untuk perangkaian kalimat—efektif dalam menekan halusinasi numerik sekaligus mempertahankan jawaban yang mudah dipahami. Konsistensi pendekatan ini teramati pada kedua subsistem yang memiliki karakteristik data berbeda: subsistem US EPA menunjukkan akurasi penuh terhadap kueri acuan basis data (18 dari 18), sedangkan subsistem *real-time* Jawa Timur memperoleh penilaian ahli yang baik (rata-rata 8,58) pada pertanyaan awam yang beragam. Pengujian komparatif memperlihatkan bahwa keandalan terhadap halusinasi bergantung pada model yang digunakan bahkan di dalam arsitektur yang sama, sehingga pemilihan model dan perancangan arsitektur merupakan dua lapis pengendalian yang saling melengkapi.

Keseluruhan pengujian tersebut sekaligus menjawab pertanyaan mengenai letak kecerdasan sistem yang dikembangkan. Kecerdasan sistem tidak terletak pada penyimpanan atau pengambilan data semata—yang memang dapat dilakukan sistem konvensional melalui kueri—melainkan pada tiga kemampuan yang masing-masing telah teruji: kemampuan menginterpretasikan pertanyaan bahasa alami menjadi aksi pengambilan data dengan memahami konteks dan maksud penggunaannya, terbukti pada pengujian persepsi awam (Subbab 4.7) dan pada keberhasilan ekstraksi parameter waktu dari pertanyaan bertanggal spesifik (Subbab 4.8); kemampuan menyajikan informasi secara benar berdasarkan data yang dimiliki, terbukti pada validasi akurasi 18 dari 18 kueri acuan (Subbab 4.3) dan audit 80 jawaban tanpa satu pun halusinasi pada model inti (Subbab 4.8); serta kemampuan membahasakan informasi kuantitatif menjadi jawaban deskriptif dalam konteks masyarakat awam, terbukti pada penilaian ahli dengan skor rata-rata 8,58 (Subbab 4.7). Dengan demikian, kecerdasan sistem bukan sekadar klaim pada penamaan, melainkan tolok ukur yang teruji.

4.10.2 Keterbatasan

Berdasarkan pengujian, teridentifikasi beberapa keterbatasan sistem sebagai berikut:

1. **Cakupan Data.** Subsistem *real-time* Jawa Timur hanya menyediakan AQI dan polutan dominan, tanpa konsentrasi mentah tiap polutan, sehingga pertanyaan mengenai nilai polutan spesifik tidak dapat dijawab pada subsistem ini.
2. **Deteksi di Luar Lingkup Berbasis Kata Kunci.** Strategi anti-halusinasi menggunakan pendekatan berbasis kata kunci yang bersifat konservatif, sehingga masih memungkinkan adanya pertanyaan sah yang ikut ditolak, maupun frasa tak terduga yang lolos. Penyempurnaan deteksi maksud dapat menjadi pengembangan lanjutan.
3. **Keterbatasan Model 8B.** Model bahasa berukuran 8B masih menunjukkan variasi dalam merangkai kalimat, misalnya pemilihan kata pembuka kategori yang belum selalu kon-

sisten, meskipun nilai dan kategori yang menjadi dasar jawaban telah benar. Variasi juga teramati pada penilaian pemilihan *tool*: pertanyaan edukatif yang memuat istilah polutan sesekali dijawab dengan laporan kondisi karena model memilih memanggil *tool* data, dan kecenderungan ini berbeda antar model—Llama 3.1 lebih agresif memanggil *tool*, sedangkan Qwen3 lebih konservatif sehingga lebih tepat sasaran pada pertanyaan edukatif. Perilaku ini merupakan konsekuensi menyerahkan keputusan pemilihan *tool* kepada model dan dapat bervariasi antar-eksekusi.

4. **Konsistensi Pernyataan Pembatas.** Pada sebagian jawaban yang menyinggung aspek kesehatan, pembukaan yang menolak memberikan informasi medis kadang tetap diikuti saran kehati-hatian yang menyinggung kondisi sensitif. Substansi saran tetap berasal dari rumusan deterministik yang aman, namun inkonsistensi ringan antara pernyataan pembatas dan isi jawaban ini merupakan keterbatasan perangkaan bahasa model 8B yang terdokumentasi.
5. **Rentang Data Historis.** Analisis pola historis masih terbatas pada data jangka pendek, sehingga analisis pola per hari dalam seminggu belum dapat disimpulkan secara meyakinkan. Pola yang bermakna baru dapat dinyatakan setelah data terkumpul dalam rentang yang lebih panjang.
6. **Pertanyaan di Luar Lingkup.** Sejumlah kebutuhan masyarakat awam, seperti implikasi medis, prediksi masa depan, kualitas udara dalam ruangan, dan kebijakan lingkungan, berada di luar lingkup data sistem. Hal ini membuka peluang integrasi dengan sumber informasi tambahan yang terkurasi pada penelitian lanjutan.
7. **Ketergantungan pada Satu Titik Pantau.** Data *real-time* tiap kota berasal dari satu titik pemantauan, sehingga nilai yang disajikan merupakan indikasi skala kota dan belum tentu merepresentasikan kondisi mikro pada lokasi spesifik pengguna. Hal ini telah diantisipasi melalui pencantuman catatan pada setiap jawaban. Temuan pemantauan bergerak di Jakarta menunjukkan bahwa variasi konsentrasi dalam satu kota dapat cukup besar [2], sehingga keterbatasan ini perlu disampaikan secara eksplisit kepada pengguna.
8. **Cakupan Penilaian Ahli.** Penilaian ahli dilakukan terhadap 12 pertanyaan perwakilan dari 40 pertanyaan responden, dan hanya pada subsistem Jawa Timur, oleh satu orang penilai. Jawaban atas pertanyaan selebihnya tetap dicatat dan dilampirkan sebagai data pendukung, namun tidak memperoleh skor. Perluasan jumlah pertanyaan yang dinilai serta penambahan penilai dapat memperkuat hasil pada penelitian lanjutan.
9. **Pemeriksaan Validasi Akurasi.** Pemeriksaan kesesuaian jawaban terhadap kueri acuan pada subsistem US EPA dilakukan oleh peneliti sendiri tanpa penilai kedua. Untuk menjaga objektivitas, acuan yang digunakan bersifat deterministik dan dapat diverifikasi ulang, yaitu hasil kueri basis data serta *breakpoint* dan *cautionary statement* standar EPA; perwakilan jawaban beserta kueri acuannya dilampirkan agar pembaca dapat memeriksanya secara mandiri.

[Halaman ini sengaja dikosongkan]

BAB V

PENUTUP

Pada bab ini akan dibahas kesimpulan yang diperoleh dari perancangan, implementasi, dan pengujian sistem Oxyra, serta saran bagi pengembangan lanjutan berdasarkan temuan dan keterbatasan yang teridentifikasi selama penelitian.

5.1 Kesimpulan

Berdasarkan hasil perancangan, implementasi, dan pengujian yang telah diuraikan pada bab-bab sebelumnya, diperoleh kesimpulan sebagai berikut.

1. **Sistem *chatbot* berbasis LLM berhasil dikembangkan dengan kemampuan memahami pertanyaan bahasa alami masyarakat awam dan menerjemahkannya menjadi pengambilan data yang tepat.** Seluruh 40 pertanyaan responden diujikan dengan gaya bahasa aslinya tanpa penyesuaian, termasuk ejaan tidak baku, lokasi yang tidak disebutkan, dan beberapa maksud dalam satu kalimat, dan sistem mampu menerjemahkannya menjadi pemanggilan fungsi serta kueri yang sesuai—termasuk mengekstrak parameter waktu dari pertanyaan bertanggal spesifik. Hasil pengambilan data kemudian dibahasakan kembali menjadi jawaban deskriptif yang dinilai ahli dengan skor rata-rata 8,58 dari skala 5–10 pada dua belas pertanyaan perwakilan. Hasil ini menunjukkan bahwa tujuan pertama tercapai: kesenjangan antara kalimat awam dan data terstruktur berhasil dijembatani pada lapisan bahasa.
2. **Sistem mampu menyediakan rekomendasi tindakan preventif yang relevan dan mudah dipahami.** Rekomendasi tidak diserahkan kepada model bahasa, melainkan ditetapkan secara deterministik oleh kode berdasarkan kategori AQI dengan mengacu pada *cautionary statement* US EPA, sementara model bahasa hanya bertugas merangkainya menjadi kalimat yang mudah dipahami. Pengujian menunjukkan bahwa mayoritas pertanyaan masyarakat awam memang berorientasi pada implikasi tindakan, seperti keamanan beraktivitas di luar, kebutuhan penggunaan masker, dan pemilihan waktu beraktivitas, sehingga pendekatan ini menjawab kebutuhan nyata pengguna.
3. **Mekanisme pengendalian halusinasi berhasil diterapkan sehingga seluruh informasi faktual bersumber dari data yang dimiliki sistem.** Strategi anti-halusinasi berlapis, yang terdiri atas pemisahan angka dari model, gerbang pertanyaan di luar lingkup, validasi wilayah, penguraian pertanyaan majemuk, dan penanganan kegagalan data, terbukti mampu menutup halusinasi numerik. Audit terhadap 80 jawaban yang dihasilkan tiap model menunjukkan bahwa model inti Llama 3.1 8B tidak menyampaikan satu pun kondisi yang tidak didukung data, sedangkan model pembanding menyampaikannya pada enam jawaban. Validasi terhadap 18 pertanyaan yang memiliki acuan kueri basis data pada subsistem US EPA juga menunjukkan kesesuaian penuh antara nilai yang disampaikan sistem dan nilai pada basis data.

Di samping ketiga kesimpulan utama tersebut, penelitian ini menghasilkan sejumlah temuan pendukung. Pengujian komparatif memperlihatkan bahwa jaminan anti-halusinasi

hanya berlaku sepanjang model bersedia memanggil fungsi yang disediakan: seluruh enam halusinasi yang teramati pada model pembandingan Qwen3 8B terjadi pada jawaban yang tidak memicu pemanggilan fungsi, yaitu ketika model menyusun jawaban dari pengetahuannya sendiri. Kepatuhan terhadap mekanisme *tool calling* dengan demikian bukan sekadar prasyarat teknis, melainkan kriteria pemilihan model yang menentukan keandalan sistem secara keseluruhan.

Temuan pendukung lainnya menyangkut sifat arsitektur yang dikembangkan. Penerapan arsitektur yang sama pada dua subsistem dengan karakteristik data yang sangat berbeda—data *real-time* berupa indeks yang telah dihitung dan data historis berupa konsentrasi mentah—dapat dilakukan tanpa perubahan mendasar pada mekanisme inti, yang menunjukkan bahwa pendekatan pemisahan peran antara kode dan model bahasa bersifat umum dan tidak terikat pada satu sumber data. Kontribusi arsitektur tersebut juga dapat ditunjukkan secara terukur: perbandingan jawaban model dasar yang identik, dengan dan tanpa arsitektur Oxyra, memperlihatkan bahwa model yang dijalankan secara mentah menghasilkan klaim kondisi udara tanpa mengakses data serta saran yang melebar ke ranah medis, sedangkan model yang sama di dalam arsitektur Oxyra menghasilkan jawaban yang seluruh nilainya dapat ditelusuri ke data. Karena model dasarnya identik, seluruh perbedaan tersebut merupakan kontribusi arsitektur, bukan kontribusi model. Kontribusi tersebut turut terkonfirmasi dari sisi persepsi pengguna: pada pengujian preferensi tersamar terhadap 10 responden awam, mayoritas responden memilih jawaban yang dihasilkan melalui arsitektur Oxyra dibandingkan jawaban model mentah pada keempat pasangan pertanyaan yang diujikan.

5.2 Saran

Berdasarkan keterbatasan yang teridentifikasi selama penelitian, disusun beberapa saran bagi pengembangan lanjutan sebagai berikut.

1. **Integrasi sumber informasi daring yang terkurasi.** Sejumlah kebutuhan masyarakat awam yang teridentifikasi dari kuesioner berada di luar cakupan data sistem, seperti penjelasan mengenai jenis pelindung pernapasan, kaitan kualitas udara dengan kondisi kesehatan tertentu, serta kebijakan lingkungan. Kebutuhan tersebut berpotensi dijawab melalui integrasi dengan sumber informasi daring, misalnya laman edukasi resmi WHO atau US EPA, menggunakan mekanisme *retrieval*. Integrasi semacam ini memerlukan kurasi sumber dan mekanisme validasi yang ketat agar jaminan anti-halusinasi yang telah dibangun tidak melemah, karena konten daring yang tidak terkurasi justru membuka kembali kemungkinan penyampaian informasi yang tidak dapat dipertanggungjawabkan. Perancangan lapisan kurasi tersebut menjadi arah pengembangan yang layak ditempuh pada penelitian lanjutan.
2. **Penyempurnaan deteksi maksud pertanyaan.** Gerbang pertanyaan di luar lingkup saat ini menggunakan pendekatan berbasis kata kunci yang bersifat konservatif, sehingga masih memungkinkan pertanyaan sah ikut ditolak maupun frasa tak terduga lolos. Penggantian dengan pendekatan klasifikasi maksud berbasis pembelajaran mesin, atau kombinasi keduanya, berpotensi meningkatkan ketepatan penyaringan tanpa mengorbankan sifat konservatif yang menjadi landasan keamanan sistem.
3. **Perluasan cakupan dan kepadatan data.** Cakupan data *real-time* saat ini terbatas pada 16 kota dengan satu titik pemantauan per kota, sehingga nilai yang disajikan merupakan indikasi pada skala kota. Penambahan titik pemantauan, baik melalui sumber data

lain maupun melalui sensor mandiri, akan memungkinkan sistem menyajikan kondisi pada skala yang lebih lokal dan lebih relevan bagi pengguna. Penambahan kepadatan titik pantau terbukti meningkatkan representasi kondisi lokal [20], dan dapat ditempuh melalui jaringan sensor tetap maupun perangkat multi-sensor bergerak yang dipasang pada kendaraan [21].

4. **Perluasan pengujian dan penilaian.** Penilaian ahli pada penelitian ini dilakukan terhadap dua belas pertanyaan perwakilan oleh satu orang penilai. Penambahan jumlah pertanyaan yang dinilai serta penambahan jumlah penilai akan memperkuat keandalan hasil evaluasi. Pengujian juga dapat diperluas dengan melibatkan pengguna akhir secara langsung untuk menilai kebermanfaatan sistem dalam penggunaan sehari-hari.
5. **Pemanfaatan model dengan kapabilitas lebih tinggi.** Sejumlah keterbatasan yang teramati, seperti ketidakkonsistenan dalam merangkai pernyataan pembatas serta variasi keputusan pemanggilan fungsi antar-eksekusi, berkaitan dengan kapasitas model berukuran 8B. Penggunaan model dengan jumlah parameter lebih besar, sepanjang tetap dapat dijalankan secara lokal, berpotensi mengurangi keterbatasan tersebut tanpa mengubah arsitektur sistem, karena arsitektur yang dikembangkan tidak bergantung pada model tertentu.
6. **Pengembangan analisis pola jangka panjang.** Analisis pola historis saat ini terbatas pada rentang data jangka pendek, sehingga pola per hari dalam seminggu belum dapat disimpulkan secara meyakinkan. Pengumpulan data yang berkelanjutan dalam rentang beberapa bulan akan memungkinkan analisis pola musiman maupun pola mingguan yang lebih bermakna, sekaligus membuka kemungkinan pengembangan fitur peramalan yang didukung data yang memadai.

[Halaman ini sengaja dikosongkan]

DAFTAR PUSTAKA

- [1] Ioannis Manisalidis, Elisavet Stavropoulou, Agathangelos Stavropoulos, and Eugenia Bezirtzoglou. Environmental and health impacts of air pollution: A review. *Frontiers in Public Health*, 8:14, 2020.
- [2] Azka Ghaida, Fadhil Muhammad Firdaus, Khalisha Meliana Qatrunnada, Daniel Peters, Beatriz Cardenas, and Puji Lestari. Spatial patterns of PM2.5 air pollution in jakarta: Insights from mobile monitoring. In *E3S Web of Conferences*, volume 485, page 06002, 2024.
- [3] Guendalina Caldarini, Sardar Jaf, and Kenneth McGarry. A literature survey of recent advances in chatbots. *Information*, 13(1):41, 2022.
- [4] Chokri Kooli. Chatbots in education and research: A critical examination of ethical implications and solutions. *Sustainability*, 15(7):5614, 2023.
- [5] Yazheng Yang, Yuqi Wang, Yaxuan Li, Sankalok Sen, Lei Li, and Qi Liu. Unleashing the potential of large language models for predictive tabular tasks in data science. *arXiv preprint arXiv:2403.20208*, 2025.
- [6] Zeel B. Patel, Yash Bachwana, Nitish Sharma, Sarath Guttikunda, and Nipun Batra. VayuBuddy: An LLM-powered chatbot to democratize air quality insights. *arXiv preprint arXiv:2411.12760*, 2024.
- [7] Lizaveta Miasayedava, Jaanus Kaugerand, and Jeffrey A. Tuhtan. Lightweight open data assimilation of pan-european urban air quality. *IEEE Access*, 11:84670–84688, 2023.
- [8] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, 2017.
- [9] Tom B. Brown, Benjamin Mann, Nick Ryder, et al. Language models are few-shot learners. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 1877–1901, 2020.
- [10] Wayne Xin Zhao, Kun Zhou, Junyi Li, et al. A survey of large language models. *arXiv preprint arXiv:2303.18223*, 2023.
- [11] Aaron Grattafiori, Abhimanyu Dubey, Abhinav Jauhri, et al. The Llama 3 herd of models. *arXiv preprint arXiv:2407.21783*, 2024.
- [12] An Yang, Anfeng Li, Baosong Yang, et al. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*, 2025.
- [13] Ziwei Ji, Nayeon Lee, Rita Frieske, et al. Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12):1–38, 2023.

- [14] Lei Huang, Weijiang Yu, Weitao Ma, et al. A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions. *ACM Transactions on Information Systems*, 2025.
- [15] Patrick Lewis, Ethan Perez, Aleksandra Piktus, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 9459–9474, 2020.
- [16] Timo Schick, Jane Dwivedi-Yu, Roberto Dessì, et al. Toolformer: Language models can teach themselves to use tools. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 36, 2023.
- [17] Yujia Qin, Shengding Hu, Yankai Lin, et al. Tool learning with foundation models. *ACM Computing Surveys*, 2024.
- [18] World Health Organization. *WHO Global Air Quality Guidelines: Particulate Matter (PM_{2.5} and PM₁₀), Ozone, Nitrogen Dioxide, Sulfur Dioxide and Carbon Monoxide*. World Health Organization, Geneva, 2021.
- [19] United States Environmental Protection Agency. Technical assistance document for the reporting of daily air quality — the air quality index (AQI). Technical Report EPA-454/B-18-007, U.S. Environmental Protection Agency, Office of Air Quality Planning and Standards, Research Triangle Park, NC, 2018.
- [20] Martha Arbayani Zaidan, Yuning Xie, Naser Hossein Motlagh, Bo Wang, Wei Nie, Petteri Nurmi, Sasu Tarkoma, Tuukka Petäjä, Aijun Ding, and Markku Kulmala. Dense air quality sensor networks: Validation, analysis, and benefits. *IEEE Sensors Journal*, 22(23):23507–23522, 2022.
- [21] Jonas Pellegrino, Hassen Aziza, Mathieu Guerin, Pascal Taranto, Wenceslas Rahajandraibe, and Blaise Ravelo. Development of a multi-sensor mobile device for urban air quality monitoring at the street corner: The SMILE project. *IEEE Access*, 13:14857–14871, 2025.

LAMPIRAN

Lampiran A. Isi Kuesioner Pengumpulan Pertanyaan Responden

Tabel berikut memuat seluruh pertanyaan yang dikumpulkan dari 40 responden melalui kuesioner daring, beserta rentang usia masing-masing responden. Gaya bahasa asli responden, termasuk ejaan tidak baku, dipertahankan tanpa perubahan sebagaimana digunakan pada pengujian.

No	Usia	Pertanyaan Responden
1	20 - 35	seberapa bagus kualitas udara di sana?
2	20 - 35	Berapa persentase polusi Berapa kelembapan
3	< 20	"Kok akhir-akhir ini aku sering batuk-batuk ya, ada hubungannya sama kualitas udara di sini?"
4	< 20	Gimana kualitas udara di daerahku sekarang? Aman nggak kalau aku jogging sore ini? Hari ini lebih baik\ldots
5	20 - 35	apakah index polusi hari ini tinggi? kenapa udara hari ini sangat panas?
6	< 20	oke
7	< 20	- Daerah sekitaran sini lagi polusi banget enggak? Aman enggak buat sepedaan sore ini? - Hari ini perlu\ldots
8	20 - 35	Cuaca, kesehatan, mungkin bisa rekomendasi masker apa yang bisa cukup untuk menyaring udara tergantung\ldots
9	20 - 35	hari ini apakah akan sangat panas / berdebu
10	20 - 35	hari ini sepanas apa (temperatur + feels likenya)? apakah hari ini bakal hujan? tolong berikan summary\ldots
11	< 20	apakah polusi akan memburuk sedara kualitas di 2030 ?
12	20 - 35	Apakah akan sangat terik
13	36 - 50	berapa tingkat polusi hari ini?
14	< 20	Hari ini polusinya memungkinkan untuk orang keluar rumah tidak
15	20 - 35	bagaimana kebersihan udara saat ini ? apakah di daerah ini baik untuk lari? baiknya jam berapa ? berapa\ldots
16	20 - 35	1. Apa penyebab dari buruknya sirkulasi udara yang ada pada kamar kos? 2. Mengapa udara di Kota Surabaya\ldots
17	20 - 35	- Bagaimana kualitas udara hari ini? Apakah aman untuk lari pagi selama 2 jam? - Di hari dan jam berapa\ldots
18	< 20	Seberapa bersih kadar udara di Surabaya?
19	20 - 35	Hari ini lagi ngapain king, Enakan mie Yamin apa mie ayam pangsit
20	20 - 35	- Kondisi udara pada hari ini apakah cocok untuk melakukan lari pagi/sore? - Kandungan gas yang ada di\ldots
21	20 - 35	Kira-kira kapan waktu yang ga terlalu panas untuk jalan-jalan keluar?
22	> 50	1. Kualitas udara luar ruang hari ini dan rata2 dalam kurun waktu yang ditentukan dan tingkat risiko\ldots

No	Usia	Pertanyaan Responden
23	20 - 35	"Hari ini udaranya lagi bersih gak ya buat jalan-jalan sore atau sekedar duduk di luar? Kira-kira jam\ldots
24	< 20	udara sekarang berapa derajat
25	20 - 35	tolong ukur berapa persen kadar polusi di daerah ini
26	20 - 35	Apakah udara di luar bersih?
27	36 - 50	kenapa udara jakarta jelek terus
28	20 - 35	Bagaimana kualitas udara di daerah surabaya pada hari ini?
29	20 - 35	1. Bagaimana kualitas udara hari ini di Surabaya? 2. Apakah saya perlu pakai masker kalau saya keluar\ldots
30	< 20	yo nda tau tanya kok tanya saya
31	< 20	Bagaimana kualitas udara di tempat tinggal saya?
32	> 50	Gimana kondisi hari ini. Tingkat polusi berapa
33	36 - 50	Bagaimana menghadapi hidup yang pasang surut
34	> 50	Bagaimana cuaca kota Malang untuk 1 bulan ke depan
35	> 50	Kapan bisa ditata peruntukan kawasan hunian dan industri dan sampah agar udara yg dihirup tetap bersih
36	> 50	Alergen apa saja yang terkandung di udara? Polutan apa yang saat ini beredar di udara? Apakah udara di\ldots
37	20 - 35	Kenapa kita bisa sakit dari udara yg kotor
38	< 20	Apakah kualitas udara saat ini cukup baik sehingga tidak berpotensi untuk menimbulkan penyakit\ldots
39	20 - 35	"Kadar polusi di sekitar saya sekarang berapa? Aman gak buat lari pagi?"Udara hari ini bagus gak buat\ldots
40	20 - 35	1. Gimana kualitas udara di daerahku hari ini? 2. Aman gak kalau aku olahraga di luar sekarang?

Lampiran B. Lembar Penilaian Ahli

Tabel berikut memuat lembar penilaian yang diisi oleh validator ahli, Prof. Ir. Joni Hermana, M.Sc.ES., Ph.D., terhadap jawaban sistem pada dua belas pertanyaan terpilih. Penilaian dilakukan pada skala 5 hingga 10 untuk kedua model, yaitu Llama 3.1 8B sebagai model inti dan Qwen3 8B sebagai model pembanding.

No	Pertanyaan	Skor Llama 3.1	Skor Qwen3
1	seberapa bagus kualitas udara di sana?	9	7
2	"Kok akhir-akhir ini aku sering batuk-batuk ya, ada hubungannya sama kualitas udara di\ldots	8	6
3	Cuaca, kesehatan, mungkin bisa rekomendasi masker apa yang bisa cukup untuk menyaring udara\ldots	7	8
4	apakah polusi akan memburuk secara kualitas di 2030 ?	8	8
5	berapa tingkat polusi hari ini?	8	9
6	Seberapa bersih kadar udara di Surabaya?	9	9
7	"Hari ini udaranya lagi bersih gak ya buat jalan-jalan sore atau sekedar duduk di luar?\ldots	7	9
8	tolong ukur berapa persen kadar polusi di daerah ini	9	9
9	1. Bagaimana kualitas udara hari ini di Surabaya? 2. Apakah saya perlu pakai masker kalau\ldots	10	10

No	Pertanyaan	Skor Llama 3.1	Skor Qwen3
10	Alergen apa saja yang terkandung di udara? Polutan apa yang saat ini beredar di udara? \ldots	10	8
11	Kenapa kita bisa sakit dari udara yg kotor	9	8
12	1. Gimana kualitas udara di daerahku hari ini? 2. Aman gak kalau aku olahraga di luar\ldots	9	8
Rata-rata		8,58	8,25

Lampiran C. Waktu Respons Seluruh Pertanyaan Pengujian

Tabel berikut memuat waktu respons kedua model untuk seluruh 40 pertanyaan responden pada subsistem Jawa Timur. Seluruh pertanyaan diujikan ke sistem tanpa penyaringan, termasuk pertanyaan yang berada di luar lingkup data maupun di luar topik. Dua belas pertanyaan di antaranya dinilai oleh ahli sebagaimana Lampiran B, sedangkan jawaban atas pertanyaan selebihnya tetap dicatat dan disajikan di sini sebagai data pendukung agar keterwakilan pemilihan sampel dapat diperiksa secara mandiri. Waktu respons sebesar 0,0 detik menandakan pertanyaan dicegat oleh gerbang anti-halusinasi sebelum mencapai model bahasa, sehingga jawaban dihasilkan langsung oleh kode tanpa proses inferensi model. Nilai tersebut tetap disertakan dalam perhitungan rata-rata karena mencerminkan waktu tunggu aktual yang dialami pengguna. Tanda “–” pada satu entri menandakan eksekusi yang melampaui batas waktu tunggu (timeout) sehingga tidak menghasilkan jawaban; entri tersebut tidak disertakan dalam perhitungan rata-rata model terkait..

No	Pertanyaan Responden	Llama (s)	Qwen3 (s)
1	seberapa bagus kualitas udara di sana?	19.6	36.0
2	Berapa persentase polusi Berapa kelembapan	0.0	0.0
3	”Kok akhir-akhir ini aku sering batuk-batuk ya, ada hubungannya sama kualitas udara di sini?”	0.0	0.0
4	Gimana kualitas udara di daerahku sekarang? Aman nggak kalau aku jogging sore ini? Hari\ldots	19.8	39.4
5	apakah index polusi hari ini tinggi? kenapa udara hari ini sangat panas?	21.5	35.6
6	oke	18.8	23.5
7	- Daerah sekitaran sini lagi polusi banget enggak? Aman enggak buat sepedaan sore ini? -\ldots	17.8	48.8
8	Cuaca, kesehatan, mungkin bisa rekomendasi masker apa yang bisa cukup untuk menyaring udara\ldots	18.5	61.9
9	hari ini apakah akan sangat panas / berdebu	17.9	40.2
10	hari ini sepanas apa (temperatur + feels likenya)? apakah hari ini bakal hujan? tolong berikan\ldots	29.5	32.5
11	apakah polusi akan memburuk sedara kualitas di 2030 ?	0.0	0.0
12	Apakah akan sangat terik	16.4	29.7
13	berapa tingkat polusi hari ini?	18.6	45.9
14	Hari ini polusinya memungkinkan untuk orang keluar rumah tidak	15.9	23.2
15	bagaimana kebersihan udara saat ini ? apakah di daerah ini baik untuk lari? baiknya jam\ldots	22.9	50.1

No	Pertanyaan Responden	Llama (s)	Qwen3 (s)
16	1. Apa penyebab dari buruknya sirkulasi udara yang ada pada kamar kos? 2. Mengapa udara di\ldots	17.5	41.5
17	- Bagaimana kualitas udara hari ini? Apakah aman untuk lari pagi selama 2 jam? - Di hari\ldots	17.1	-
18	Seberapa bersih kadar udara di Surabaya?	16.2	25.0
19	Hari ini lagi ngapain king, Enakan mie Yamin apa mie ayam pangsit	17.9	27.7
20	- Kondisi udara pada hari ini apakah cocok untuk melakukan lari pagi/sore? - Kandungan gas\ldots	19.3	93.3
21	Kira-kira kapan waktu yang ga terlalu panas untuk jalan-jalan keluar?	16.5	56.2
22	1. Kualitas udara luar ruang hari ini dan rata2 dalam kurun waktu yang ditentukan dan tingkat\ldots	0.0	0.0
23	”Hari ini udaranya lagi bersih gak ya buat jalan-jalan sore atau sekadar duduk di luar?\ldots	11.1	51.6
24	udara sekarang berapa derajat	20.2	33.7
25	tolong ukur berapa persen kadar polusi di daerah ini	0.0	0.0
26	Apakah udara di luar bersih?	17.2	48.2
27	kenapa udara jakarta jelek terus	17.6	27.4
28	Bagaimana kualitas udara di daerah surabaya pada hari ini?	16.3	26.3
29	1. Bagaimana kualitas udara hari ini di Surabaya? 2. Apakah saya perlu pakai masker kalau\ldots	23.8	37.8
30	yo nda tau tanya kok tanya saya	16.6	25.4
31	Bagaimana kualitas udara di tempat tinggal saya?	0.0	0.0
32	Gimana kondisi hari ini. Tingkat polusi berapa	19.9	33.5
33	Bagaimana menghadapi hidup yang pasang surut	14.6	28.7
34	Bagaimana cuaca kota Malang untuk 1 bulan ke depan	17.0	23.9
35	Kapan bisa ditata peruntukan kawasan hunian dan indistri dan sampah agar udara yg dihirup\ldots	0.0	0.0
36	Alergen apa saja yang terkandung di udara? Polutan apa yang saat ini beredar di udara? \ldots	20.1	34.3
37	Kenapa kita bisa sakit dari udara yg kotor	21.3	33.7
38	Apakah kualitas udara saat ini cukup baik sehingga tidak berpotensi untuk menimbulkan penyakit\ldots	18.7	34.8
39	”Kadar polusi di sekitar saya sekarang berapa? Aman gak buat lari pagi?” ”Udara hari ini\ldots	20.1	39.6
40	1. Gimana kualitas udara di daerahku hari ini? 2. Aman gak kalau aku olahraga di luar\ldots	19.5	37.0

BIOGRAFI PENULIS



Cedric Anthony Edysa, atau yang biasa dikenal sebagai Cedric, lahir di Jakarta, Jawa Barat pada 7 Juni 2004. Penulis merupakan anak pertama dari dua bersaudara yang tinggal dan tumbuh besar di Kota Jakarta. Ketertarikan mendalam penulis di bidang teknologi mengantarkan penulis yang telah menyelesaikan masa sekolah di SMAK 3 Penabur Jakarta ke jenjang strata satu di Departemen Teknik Komputer Fakultas Teknologi Elektro dan Informatika Cerdas Institut Teknologi Sepuluh Nopember (ITS) pada tahun 2022.

Penulis merupakan pribadi yang memiliki ketertarikan dalam menjelajahi topik - topik yang berkaitan dengan bidang teknologi secara tekun dan mendalam. Dalam masa kuliah, penulis tertarik dengan topik seperti *Robotics And Intelligent System*, Pengembangan Chatbot (*Website Development*), dan *Machine Learning*. Penulis juga aktif dalam mengembangkan minat dan bakat di luar perkuliahan. Hal ini dibuktikan dengan rekam jejak organisasi dan kepanitian dari penulis seperti Ketua Logistik PMK divisi Natal Paskah, Asisten Laboratorium *Robotics And Intelligent System*, hingga menjadi student mentor di UKM Golf. Hingga saat ini penulis terus menekani ketertarikan dan kemampuan yang dimiliki di bidang teknologi, terkhususnya pada bidang *Artificial Intelligence* dan *Website Development*.

Pada penelitian tugas akhir ini, penulis memilih mengembangkan sistem *Chatbot* sebagai asisten informasi cerdas yang berfokus pada bidang kualitas udara. Keresahan penulis mengenai pentingnya kesehatan lingkungan, terutama dalam bidang kualitas udara, menginspirasi dibuatnya tugas akhir ini. Bagi pembaca yang memiliki kritik, saran, atau pertanyaan mengenai tugas akhir ini dapat menghubungi penulis melalui surel anthony.cedric76@gmail.com.

[Halaman ini sengaja dikosongkan]